Entrega 02: Codificação, Metodologia Implementada e Resultados

Detecção de Sonolência em Dispositivos Móveis: Avaliação da Generalização entre Sonolência Atuada e Real

Projeto Transformador II, Ciência da Computação, PUCPR. Turma 8ºA, Equipe 14. André Luís O. F. da Silva, Bruno Rodolfo da Silveira, Bruno Sandoval Ribeiro, Paulo Henrique Perin. Orientador: Prof. Júlio César Nievola.

Versão de 06/11/2026 (prazo da entrega: 09/11/2026, adiado de 31/10). Repositório: https://github.com/BrunoRodolfoo/deteccao-sonolencia

> Todos os números deste relatório foram copiados dos arquivos de `results/` gerados pelos scripts, e o arquivo de cada tabela aparece entre parênteses. Os que também estão no artigo têm macro em `paper/numeros.tex`, conferida por `src/experiments/conferir_numeros.py` (709 números, 0 divergências em 06/11/2026). Nenhum valor foi estimado.
>
> Celular: o app 2.1 foi medido nos dois aparelhos, com 3 execuções em cada: no Galaxy S23 Ultra em 05/11 e no iPhone 17 Pro em 06/11. Os números ficam em `results/exp4_phone_latency.md`.
>
> A rodada preliminar dos Exp. 5 e 6 (janelas de 30 s, só o Fold 1) foi descartada e não é citada.

1. Resumo executivo

O projeto implementou, executou e documentou seis experimentos e um app de demonstração.

- Os Exp. 1 a 4 ficaram prontos em 20/09.
- Os Exp. 5a, 5b e 6 foram feitos em 27/09, depois da troca do NTHU-DDD, que não foi obtido, por DMD (sonolência encenada) e NITYMED (condução noturna real). A justificativa está em `docs/TROCA_DATASETS.md`.
- Em 26/10 entraram os controles da queda do Exp. 5b (`src/experiments/exp5b_robustez.py`), que mudaram a leitura da PP1.
- A base de sonolência real continua sendo a UTA-RLDD, com os vídeos dos 60 sujeitos processados.

Achados centrais:

- PP1: sono encenado → sono real (Exp. 5b). Com o mesmo extrator e as mesmas características, os modelos treinados no DMD reconhecem o sono real pior que os treinados na própria UTA-RLDD.
  - A regressão logística (RL) perde de 5,4 a 9,8 pontos de AUC por janela nas quatro formas testadas de normalizar os dados de cada pessoa, sempre com IC acima de zero.
  - O Random Forest (RF) perde 10,9 [6,7; 15,7] na normalização principal. Com a referência no vídeo de pouca vigilância ou sem centragem, perde de 2,1 a 2,3, sem diferença detectável: na UTA-RLDD, as janelas alertas saem do mesmo vídeo da referência, e o RF treinado nela aproveita essa semelhança.
  - O achado mais firme: o modelo do DMD reconhece 82,0% das janelas alertas reais, mas só 48,4% das sonolentas, e a sonolência atuada se mostra mais extrema que a real. O volume do treino explica pouco (B treinado com 13 sujeitos).
  - O extrator não explica a perda: trocar o extrator oficial (dlib) pelo nosso (MediaPipe) custa +2,0 pp [–4,8; +8,5] (Exp. 5a).
- Vazamento entre treino e teste. Com partição aleatória por janela, os mesmos dados do Exp. 1 vão de 54,2% a 99,5% de BSA (+45,3 pp; Exp. 2): sequências vizinhas dividem 28 das 30 piscadas, e janelas do mesmo vídeo caem nos dois lados. No cenário do Exp. 5b, a inflação é de 12,6 pp no RF e de só 1,2 pp na RL. Isso não explica os 90% do NTHU-DDD da literatura, que foram medidos com outras pessoas no teste.
- PP2: custo no celular. A EyeNet int8 tem 72,1 KB, com queda de no máximo 0,31 pp de acurácia. Com o app 2.1, em 3 execuções por aparelho, o tempo por quadro (p50) foi de 11 a 12 ms no iPhone 17 Pro (mediana de 11 ms) e de 39,1 a 40,1 ms no Galaxy S23 Ultra (mediana de 39,5 ms).
- PP3: condições adversas.
  - Óculos é o que mais derruba a transferência do estado ocular (CEW → MRL: AUC 65,1 com óculos, 93,4 sem; Exp. 3).

    - À noite (NITYMED), a SNR do EAR cai para 7,2, contra 21,5 na UTA-RLDD. Mas o DMD com os mesmos motoristas e o carro em movimento, de dia, já chega a 8,7, e a diferença noite – movimento (–1,6 [–3,7; +1,1]) não exclui zero: parte da degradação atribuída à noite vem do movimento (Exp. 6).
- App de demonstração (PWA 2.1). O app alarma por sinais visíveis (olhos, bocejo e cabeça), num nível de 0 a 100 que explica cada ponto. A regra não é mais precisa que os modelos: com o mesmo falso alarme, a RL do DMD acha tantas janelas sonolentas quanto ela. A vantagem da regra é ser explicável e não precisar de treino.
    - Na direção real do DMD, com motoristas acordados, o app ficou 3,3% do tempo em vermelho, e 16 de 17 sessões não tiveram alarme.
    - O estado do olho por quadro tem kappa 0,938 (offline) e 0,902 (navegador).
    - Desde 26/10, o app funciona sem internet (`app/pwa/vendor/`, baixada por `tools/baixar_dependencias_app.sh`).
    - Teste independente em sono real (26/10): em 24 pessoas da UTA-RLDD que não entraram no ajuste, sentadas e sem dirigir, houve alarme em 2 dos 24 vídeos acordados, e 15 dos 24 sonolentos chegaram ao vermelho; 7 sonolentos ficaram verdes. AUC sonolento × acordado de 0,812 [0,705; 0,918].
    - Sensibilidade dos pesos (26/10): em 300 combinações sorteadas dos pesos e limiares do nível, o falso alarme na direção real do DMD ficou de 1,7% a 4,9% do tempo (percentis 5 e 95; a configuração final dá 3,3%).
    - Nas mesmas 24 pessoas (27/10), a AUC por vídeo do RF treinado no DMD foi de 0,811, a da regra do rótulo, de 0,853, e a do RF treinado na própria UTA-RLDD, de 0,953 com a centragem pelo vídeo acordado e 0,806 sem ela. O app, sem treino (0,812), fica no nível deles.

2. O que foi feito em outubro

Data	O que foi feito	Onde ver
04/10	O orientador autorizou a troca de bases, verbalmente	`docs/TROCA_DATASETS.md`
06/10	Artigo enxugado para 7 páginas, sem travessões e com a Fig. 1 refeita em preto e branco; números, artigo e pôster refeitos e conferidos	`results/logs/atualizar_celular_20261006_161528.log`
06/10	Limpeza da pasta: rodada preliminar, logs repetidos e cópias sem uso foram para a Lixeira	`docs/ESTRUTURA.md`, seção 3
26/10	Controles da queda do Exp. 5b: referência no vídeo de pouca vigilância, IC em dois níveis (motoristas do DMD reamostrados e C treinado de novo), B treinado com 13 sujeitos, vazamento no cenário do Exp. 5b e ponto de operação da regra	`results/exp5b_robustez.md`; log `results/logs/exp5b_robustez_20261026-2051.log`
26/10	Banca simulada e reescrita do artigo, com a leitura nova da PP1, do vazamento e da regra × modelos: 8 páginas, 31 referências, Tabelas I a V e 3 figuras; números refeitos e conferidos (0 divergências)	`paper/README.md`, `results/numeros_resumo.md`
26/10	App 2.1 sem internet: dependências locais em `app/pwa/vendor/` (13 arquivos, cerca de 36 MB, fora do Git), baixadas e conferidas pelo SHA-256 por `tools/baixar_dependencias_app.sh`; o `serve_https.py` confere a pasta ao subir e oferece baixar o que faltar	`app/pwa/README.md`, seção 7
26/10	Sensibilidade dos pesos do nível do app: 353 configurações no DMD (uma mudança por vez e 300 sorteadas, com cada peso, teto e decaimento de 0,7 a 1,3 vez e os limiares 40 e 70 deslocados em até 10 pontos)	`results/app_sensibilidade_pesos.md`; log `results/logs/app_sensibilidade_pesos_20261026-224834.log`
26/10	Teste independente do app em sono real: o motor do app em 24 pessoas da UTA-RLDD (todas as dos folds 2 e 4, regra fixada antes de rodar), um vídeo acordado e um sonolento de cada	`results/app_validacao_uta.md`; log `results/logs/app_validacao_uta_20261026-230247.log`
27/10	Comparação do app com os modelos do Exp. 5b e com a regra do rótulo nas mesmas 24 pessoas (AUC por vídeo)	`results/app_comparacao_uta.md`; `src/experiments/comparar_app_uta.py`
26/10	Figura de amostras refeita só com o MRL Eye (a anterior tinha recortes do CEW, cuja licença proíbe redistribuição); figuras de reserva do artigo e `src/pipeline_b/run_all_eye.sh` foram para a Lixeira; o `run_all.sh` passou a gravar os logs do Exp. 3 e a rodar os controles do Exp. 5b	`docs/ESTRUTURA.md`, seção 3

3. Como verificar em 5 minutos

Na raiz do repositório, com o Node 18 ou mais novo e um ambiente Python leve: para os testes e a conferência bastam numpy, pandas, scipy e pytest (o `pytest` está no `requirements.txt`; o TensorFlow só é preciso para refazer os experimentos). O `.venv` completo (`README.md`, seção 5) também serve. Nenhum destes comandos precisa dos dados de `data/` nem refaz experimentos.

```
node app/pwa/test_engine.mjs                                    # motor do app
.venv/bin/python -m pytest -q src/features/test_features.py   # piscadas, janelas, sequências e rótulos
bash run_all.sh --dry-run                                       # o pipeline inteiro, só os comandos
.venv/bin/python src/experiments/conferir_numeros.py --sem-latex   # todos os números do artigo e do pôster
```

Comando	O que confere	Resultado esperado
`test_engine.mjs`	o motor do app (`engine.js`): EAR, piscadas, PERCLOS, bocejo, cabeça, nível e histerese	"217 passaram, 0 falharam", em menos de 1 s
`test_features.py`	detector de piscadas, janelas de 10 s, sequências de 30 piscadas e rótulos do DMD	"19 passed", em cerca de 1 s
`run_all.sh --dry-run`	a ordem das 11 etapas (`--lista`) e o comando de cada uma, inclusive `exp5b_robustez.py` na etapa exp5b	lista os comandos e termina sem rodar nada
`conferir_numeros.py --sem-latex`	recalcula cada número de `paper/numeros.tex` e `poster/numeros.json` a partir dos CSV de `results/`, com leitura e formatação próprias	"709/709 ok" e "divergências 0", em poucos segundos

Com `--sem-latex`, a conferência não precisa do tectonic; sem essa opção, ela também compila um documento de teste com todos os números. Nos dois casos, ela reescreve a seção "Conferência automática" de `results/numeros_resumo.md`. Para ir além, escolha um número do artigo (por exemplo, 48,4) e procure-o em `results/numeros_resumo.md`, que diz o arquivo e a coluna de origem.

4. O que foi implementado

Módulo	Conteúdo	Testes e validações
`src/baseline/` (Entrega 01)	download das características oficiais da UTA-RLDD, folds, LogReg, SVM e RF	segunda execução reprodutível (24/08 e 26/08)
`src/experiments/uta_common.py`, `blink_models.py`	carga dos 5 folds, reconstrução de vídeo e sujeito (58 sujeitos, 8.661 sequências), métricas BSA e VA, esquemas 3c, B1, B2 e B3; LogReg, SVM, RF, LSTM, CNN1D	`assert` contra os índices oficiais
`src/experiments/exp1_intra.py`, `exp2_leakage.py`	Exp. 1 e 2 + exportação TFLite do LSTM	TFLite × Keras: max|dif| 6,5e-6
`src/pipeline_b/`	Exp. 3 (EyeNet, protocolos A, B, C e D por condição), Exp. 4 desktop (TFLite fp32 e int8) e a figura de amostras do MRL Eye	fp32 idêntico ao Keras; ablação da BatchNorm
`src/features/extract_signals.py` (.venv-mp)	vídeo → EAR, MAR e pose por quadro (MediaPipe Face Mesh 0.10.21): DMD (65 sessões), NITYMED (126), UTA-RLDD (182 arquivos); incremental, escrita atômica	alinhamento anotação × vídeo do DMD verificado (deslocamento 0)
`src/features/` (`blinks.py`, `dmd_labels.py`, `windows.py`, `sequences.py`, `uta_oficial.py`)	piscadas, janelas de 10 s (5 e 15 s), rótulos do DMD, sequências de 30 piscadas, mapeamento sujeito oficial ↔ pasta	19 testes (`test_features.py`); validação do detector contra a anotação do DMD
`src/experiments/exp5a_*.py`	Exp. 5a: nosso extrator × características oficiais (5 folds, 47 sujeitos confirmados); detector do dlib (.venv-mp)	bootstrap por sujeito, permutação pareada, McNemar; 3 checagens independentes do mapeamento
`src/experiments/exp5_transfer.py`	Exp. 5b: DMD → UTA-RLDD (A, B e C), 8 sensibilidades, controle do vídeo de referência, importância por permutação	referência de normalização separada da avaliação (0 janelas sobrepostas)

Módulo	Conteúdo	Testes e validações
`src/experiments/exp5b_robustez.py` (26/10)	controles da queda B – C: referência no vídeo de pouca vigilância, bootstrap em dois níveis com C treinado de novo, B com 13 sujeitos (20 sorteios), vazamento no cenário do Exp. 5b, ponto de operação da regra	antes das análises, refaz a queda principal e confere com o Exp. 5b (10,9 [6,7; 15,7] no RF e 9,8 [3,7; 16,0] na RL)
`src/experiments/exp6_*.py`	Exp. 6: detecção de rosto, qualidade do EAR, taxa de disparo, luminância medida	DMD em movimento × parado como controle, pareado por motorista
`src/experiments/comparar_app_uta.py` (27/10)	AUC por vídeo do app, dos modelos do Exp. 5b e da regra do rótulo nas mesmas 24 pessoas do teste do app	IC 95% por bootstrap de sujeitos
`src/experiments/make_paper_numbers.py`, `conferir_numeros.py`	todos os números do artigo e do pôster (709 em 06/11) → `paper/numeros.tex`, `poster/numeros.json`, `results/numeros_resumo.md`	recálculo independente: 0 divergências
`app/pwa/` (demonstração, 2.1)	câmera → MediaPipe Face Landmarker (WASM/WebGL) → olhos (EAR + blendshape), bocejo (jawOpen/MAR), cabeça (matriz de pose) → nível de 0 a 100 com histerese → alarme sonoro; CNN e LSTM como estimativa; benchmark de 60 s enviado ao Mac; funciona sem internet com `vendor/`	217 asserções em Node; validação offline no DMD e no navegador com 14 vídeos reais (`results/app_validacao*.md`)
`app/android/` (Kotlin)	lógica anterior (1.0): PERCLOS e LSTM; benchmark nativo	nunca compilado (sem JDK e SDK); JUnit escrito, não executado
`tools/`	obtenção de dados (UTA-RLDD, DMD), dependências do app (`baixar_dependencias_app.sh`, com conferência por SHA-256), importação do benchmark do celular, `atualizar_celular.sh` (um comando: importa → figura → números → artigo → pôster), `gerar_pdf_relatorio.py` (PDF deste relatório) e validação do app em `app_validacao/`: motor offline no DMD, app no navegador com vídeos reais, sensibilidade dos pesos (`sensibilidade_pesos.mjs`) e teste independente na UTA-RLDD (`validar_motor_uta.mjs`, com os sinais de `extrair_sinais_app.py --uta-folds`)	testado de ponta a ponta com os dados atuais; a sensibilidade só grava resultado se a configuração sem mudança reproduzir a validação do DMD
`paper/`, `poster/`	artigo IEEE (`artigo.tex`, `refs.bib` verificado), pôster no template do professor	compilação com tectonic; PDF do pôster pelo Chrome headless, mudo
`run_all.sh`, `requirements*.txt`	reprodução completa em 11 etapas (a etapa exp5b roda também os controles); dois ambientes (`.venv`, `.venv-mp`) com congelamento completo	`--dry-run`, `--smoke`

5. Checkpoints (`models/`)

Os modelos treinados ficam em `models/`. Os pequenos e os usados pelo app ou por outros experimentos são versionados; os grandes, que um script refaz em minutos, ficam fora do Git.

Arquivos	O que são	Para que servem	Git
`LogReg_fold{1..5}.pkl`, `SVM-RBF_fold{1..5}.pkl`, `RandomForest_fold{1..5}.pkl` (raiz)	baseline da Entrega 01: classificadores clássicos sobre 24 estatísticas das sequências oficiais, um por fold	reproduzir a baseline (`src/baseline/train.py`; `results/baseline_uta_rldd.md`)	sim

Arquivos	O que são	Para que servem	Git
`exp1/` (100 arquivos)	Exp. 1: LogReg, SVM-RBF e RF (`.pkl`), LSTM e CNN1D (`.keras`), por fold (5) e por esquema (3c, B1, B2, B3)	refazer as tabelas do Exp. 1 sem treinar de novo; o `exp1_intra.py` os refaz em cerca de 10 min	não
`exp1_best_temporal.txt`	o melhor modelo temporal do Exp. 1 (`LSTM`)	escolhe o modelo exportado para o app	sim
`blink_temporal.tflite` + `blink_temporal.json`	LSTM de piscadas do fold 3 em TFLite (101,8 KB, 5.324 parâmetros), com o contrato de entrada (30 × 4, ordem das características, normalização)	estimativa experimental no app (soma no máximo 10 pontos) e latência do Exp. 4	sim
`exp3/eyenet_mrl_fold{1..5}.keras`, `exp3/eyenet_mrl_final.keras`	EyeNet treinada no MRL Eye: 5 folds por sujeito e o modelo final com os 37 sujeitos	Exp. 3 (protocolos A e B); o modelo final é o que vira TFLite	sim
`exp3/eyenet_cew_{patch,crop}_fold{1..5}.keras`	EyeNet treinada no CEW, com o recorte oficial 24×24 e com o recorte da face	Exp. 3 (protocolos C e D)	sim
`exp3/mobilenetv3_mrl_fold1.keras`	MobileNetV3-Small no fold 1	referência opcional do Exp. 3	não
`eye_state_fp32.tflite`, `eye_state_int8.tflite` + `eye_state.json`	EyeNet final em TFLite (248,2 KB e 72,1 KB), com o contrato de entrada e saída e as métricas da quantização	Exp. 4 (quantização e latência) e a CNN do olho que o app mostra	sim
`exp5/exp5b_final_C_{principal,sem_normalizacao}_{RF,LR}.joblib` + `exp5b_final_modelos.json`	os quatro modelos de transferência do cenário C (treino em todo o DMD: 510 janelas de 13 motoristas), com as características, a normalização e os limiares calibrados no DMD	Exp. 5b (cenário C) e Exp. 6 (taxa de disparo do modelo do DMD)	sim

Arquivos	O que são	Para que servem	Git
`exp6/rf_uta_*.joblib`, `exp6/rf_dmd_sem_taxa_rosto.joblib` + `exp6/modelos.json`	RF treinados em todas as janelas B3 da UTA-RLDD e variantes sem a taxa de rosto	Exp. 6 (disparo do modelo da UTA e controles); o `run_exp6.sh` os refaz em cerca de 1 min	não

Os `.tflite` e `.json` da raiz têm cópias idênticas em `app/pwa/models/`, que é o que o app carrega.

6. Metodologia implementada

6.1 Dados

Base	Natureza	Uso	Sujeitos e vídeos usados
UTA-RLDD (Ghoddoosian et al., 2019)	sonolência real autorrelatada (KSS 0, 5 e 10), celular ou webcam	teste real; características oficiais nos Exp. 1, 2 e 5a	60 sujeitos, 180 vídeos lógicos (182 arquivos); os `.npy` oficiais têm 58 sujeitos
DMD (Ortega et al., 2020)	sonolência encenada, carro parado (s5); direção segura com o carro parado (s2 e s3) e em movimento (s1)	treino atuado (Exp. 5b); controle de movimento (Exp. 6); validação do app	13 sujeitos com s5 (16 sessões) + sessões de distração (65 sessões no total, 14 sujeitos)
NITYMED (Petrellis et al., 2022)	condução noturna real; bocejos e microssonos de autenticidade não documentada	condição noite (Exp. 6), sem acurácia	126 vídeos (19 de microssono, 107 de bocejo; a ficha oficial diz 130)
MRL Eye (Fusek, 2018)	recortes infravermelhos com metadados	Exp. 3	84.898 recortes, 37 sujeitos
CEW (Song et al., 2014)	faces RGB *in the wild*	Exp. 3	2.423 faces, 4.846 olhos

Detalhes de obtenção, licença e citação obrigatória: `README.md` (seção 3) e `data/README.md`.

6.2 Exp. 1: intra-conjunto (teto na UTA-RLDD)

Protocolo oficial: treino nos 4 folds restantes, teste no fold em questão, 5 vezes. Modelos clássicos sobre 24 estatísticas por sequência (média, desvio, mín., máx., mediana e IQR de cada característica) e modelos temporais sobre a sequência bruta 30×4. Métricas por fold e média ± desvio populacional: BSA (acurácia por sequência), acurácia balanceada, F1 macro, AUC macro OvR e VA (acurácia por vídeo, voto majoritário das janelas do vídeo; empate → maior probabilidade média). Esquemas: 3 classes e três harmonizações binárias (B1 alerta × resto; B2 sonolento × resto; B3 alerta × sonolento). Sensibilidade a épocas (15 × 50) para os temporais.

6.3 Exp. 2: vazamento entre treino e teste

Pool: as 8.661 sequências de teste dos 5 folds (cada sequência aparece uma vez), com `video_id` e `subject_id` reconstruídos. Três partições em validação cruzada 5-fold: (i) por janela aleatória (janelas sobrepostas do mesmo vídeo em treino e teste; sementes 42, 43 e 44), (ii) por vídeo (nenhum vídeo dos dois lados, mas os outros dois vídeos do sujeito no treino), (iii) por sujeito (folds oficiais). Mesmos modelos e hiperparâmetros do Exp. 1 (RF e o melhor temporal, LSTM). A inflação é a diferença (i) – (iii) e (ii) – (iii) em cada métrica. Em 26/10, a mesma comparação foi refeita no cenário do Exp. 5b (janelas de 10 s, duas classes; `exp5b_robustez.py`, seção 4).

6.4 Exp. 3: estado ocular intra e entre bases

EyeNet: entrada 48×48×1 em [0,1]; Conv(16)-BN-ReLU-Pool / Conv(32)-BN-ReLU-Pool / Conv(64)-BN-ReLU-Conv(64)-BN-ReLU-Pool / GAP / Dense(32) / Dropout(0,3) / sigmoide; 62.865 parâmetros; Adam 1e-3, lote 128, no máximo 12 épocas, EarlyStopping (val_loss, paciência 3), ReduceLROnPlateau; aumento de dados (espelhamento, rotação ±10°, translação ±8 %, zoom ±10 %, brilho ±15 %, contraste ±20 %); BatchNorm com momento 0,9 (ablação com 0,99 em `results/exp3_bn_momentum_ablation.csv`: resultados comparáveis). Protocolos: A: GroupKFold de 5 folds por sujeito no MRL (treino subamostrado a 25.000 imagens estratificadas por sujeito × classe; 10 % dos sujeitos de treino para early stopping; teste em todas as imagens dos sujeitos de teste), com predições

fora da amostra estratificadas por condição; B: MRL → CEW (os 5 modelos de A e um modelo final treinado nos 37 sujeitos); C: CEW → MRL (5 folds por face + ensemble), por condição do MRL; D: CEW → CEW (faces não vistas). Referência opcional: MobileNetV3-Small 0,75 no fold 1.

6.5 Exp. 4: custo no celular

Exportação do EyeNet final para TFLite fp32 e int8 (quantização pós-treino completa, E/S uint8, conjunto representativo de 500 imagens do MRL) e do LSTM de piscadas (fp32, `unroll=True`, só operações builtin). Métricas: queda de acurácia e AUC dos `.tflite` em relação ao Keras (MRL e CEW), tamanho em KB e latência em lote 1 (50 aquecimentos + 500 execuções, 1 e 4 threads) no desktop. No celular: latência p50 e p95 por estágio (landmarker, CNN dos dois olhos, motor ou LSTM, total por quadro) e quadros por segundo em benchmarks de 60 s, medidos pela PWA (MediaPipe WebAssembly/WebGL + tfjs-tflite), que envia o resultado sozinha ao Mac; o app Android nativo (TFLite + MediaPipe Tasks) fica como caminho alternativo, ainda não compilado. Protocolo em `app/pwa/README.md` e `docs/GUIA_EQUIPE.md`, seção 1.

6.6 Extração de sinais e características (base dos Exp. 5a, 5b e 6)

Sinais. MediaPipe Face Mesh em modo vídeo, como no app. EAR e MAR em pixels; aproximações da pose. Quadros sem rosto ficam como NaN. O lado maior do quadro é reduzido para no máximo 1280 px, e a rotação do metadado é corrigida.

Piscadas. Limiar de 0,75 × a mediana do EAR num trecho de referência do próprio sujeito. A referência é separada da avaliação:

- UTA-RLDD: último terço do vídeo alerta. Os dois terços iniciais são o alerta avaliado.
- DMD: trechos de direção segura da sessão s3.
- NITYMED: primeiro terço do vídeo, um desvio inevitável, porque a base não tem trecho alerta.

As janelas de referência e as que tocam nela nunca entram em treino nem em teste.

Janelas. 10 s com passo de 5 s nas três bases. Os trechos de direção segura do DMD duram de 10 a 26 s, então as janelas de 30 s do planejamento não cabem neles.

Cada janela tem 11 características: PERCLOS, taxa de piscadas, duração média, maior fechamento, fechamentos de 0,5 s ou mais, EAR médio e desvio, amplitude, velocidade, fração de bocejo e taxa de rosto. A normalização principal é a centragem pelo sujeito: x − média da referência.

Rótulos.

- DMD: alerta = janelas inteiras dentro de direção segura da s2 (carro parado, como a s5); sonolento = janelas da s5 com fechamento anotado de 0,5 s ou mais ou bocejo; as janelas da s5 sem sinal ficam de fora.
- UTA-RLDD: KSS do vídeo. B3 (0 × 10) é o esquema principal.

Vídeos divididos. Em dois sujeitos (F3_32, F5_49), as partes do vídeo sonolento são tratadas como um vídeo lógico.

6.7 Exp. 5a: validação do nosso extrator

O RF do Exp. 1, treinado nas características oficiais dos outros 4 folds, é aplicado às características oficiais e às nossas dos mesmos vídeos.

Trabalhamos com os 47 sujeitos cujo par entre sujeito oficial e pasta de vídeo foi confirmado. O mapeamento foi reconstruído por engenharia reversa dos `.npy` e verificado por três checagens independentes.

A diferença mede o custo de trocar o extrator. Complemento: cada extrator treinado e testado nas próprias características (5 folds e LOSO).

Incerteza:

- IC 95% por bootstrap sobre sujeitos (1.000 reamostragens);
- permutação pareada (10.000 sorteios);
- McNemar na VA.

6.8 Exp. 5b: transferência atuado → real (PP1)

Três avaliações com as mesmas características e o mesmo extrator:

- (A) DMD → DMD, deixando um sujeito de fora;
- (B) UTA → UTA, nos 5 folds oficiais;
- (C) DMD → UTA, com um modelo treinado em todo o DMD.

Modelos: Random Forest (300 árvores) e regressão logística, ambos balanceados, com hiperparâmetros fixos.

Limiares:

- 0,5, fixado antes;
- calibrado só no treino (em C, no DMD, sem olhar a UTA).

Queda da PP1 = B − C, pareada por sujeito da UTA. Métricas por janela e por vídeo (média dos escores das janelas do vídeo lógico). IC 95% por bootstrap sobre sujeitos.

Sensibilidades: sem normalização; alerta da s1; s5 sem sinal como alerta; janelas de 5 s e 15 s; referência espelhada; sem o motorista gE_29.

Controle do vídeo de referência: AUC entre os vídeos de código 5 e 10 (KSS 6 e 7 contra 8 e 9), dois vídeos que não são a referência.

Controles acrescentados em 26/10 (`src/experiments/exp5b_robustez.py`, mesmos dados e mesma receita de modelos):

- referência no vídeo de pouca vigilância: a centragem da UTA-RLDD passa a usar a média das janelas do vídeo de pouca vigilância do sujeito (código 5, KSS 6 e 7), que não entra no B3; assim, nem as janelas alertas nem as sonolentas vêm do vídeo da referência;
- bootstrap em dois níveis: em cada reamostragem, os 13 motoristas do DMD também são sorteados com reposição, e C é treinado de novo;
- volume do treino: B treinado com só 13 sujeitos da UTA-RLDD por fold (todas as janelas deles ou 510 janelas, o tamanho do treino de C), em 20 sorteios;
- vazamento no mesmo cenário: folds oficiais por sujeito contra partição aleatória das janelas (sementes 42, 43 e 44);
- ponto de operação da regra: para cada modelo, o limiar que dá o mesmo falso alarme da regra nas janelas alertas. Esse limiar usa o rótulo do teste: é só um diagnóstico de onde a regra fica nas curvas ROC.

6.9 Exp. 6: noite (PP3)

Três medidas nas três bases:

- (a) detecção de rosto por quadro;
- (b) qualidade do EAR, em que a SNR rápida é a amplitude das piscadas dividida pelo ruído quadro a quadro (MAD do resíduo da mediana móvel de 1 s);
- (c) taxa de disparo: janelas marcadas como sonolentas pelo modelo do DMD (Exp. 5b), pelo modelo da UTA (B3) e por uma regra sem treino (fechamento de 0,5 s ou mais ou bocejo).

O DMD em movimento (s1) × parado (s2), pareado por motorista, separa o efeito do movimento.

O NITYMED não tem classe alerta, e nenhuma acurácia é calculada nele. Também medimos a luminância do rosto e dos olhos e a compressão dos vídeos.

6.10 App de demonstração (PWA 2.1) e a validação dele

Detector.

- Olhos: EAR calibrado com o blendshape eyeBlink, com travas para "olhar para baixo". O PERCLOS de 60 s conta só fechamentos de 0,5 s ou mais. Fechamentos longos e microssonos (1 s ou mais) também entram.
- Bocejo: jawOpen ou MAR relativo sustentado por 1,5 s ou mais.
- Cabeça: queda com os olhos fechados ou cabeceio. Cabeça baixa com os olhos abertos conta como distração e vale 0 ponto.

- LSTM: soma no máximo 10 pontos, e só quando os sinais visíveis já passam de 40.

Nível. Os sinais formam um nível de 0 a 100, com decaimento e histerese: amarelo a partir de 40, vermelho a partir de 70. O microssono e a cabeça caindo com os olhos fechados levam ao vermelho na hora. O alarme sonoro começa com volume de 20%. Os pesos do nível são escolhas de projeto documentadas, não ajustadas em sonolência real; a regra dos olhos e os ajustes finais foram escolhidos nos dados da validação, por isso os números dela são de desenvolvimento.

Sem internet. As dependências que viriam da internet (MediaPipe com os WASM, o `face_landmarker.task`, TensorFlow.js e tfjs-tflite) ficam em `app/pwa/vendor/`, nas versões fixas do `app.js`. O app usa essa cópia primeiro e a CDN só como reserva.

Validação.

- Offline: o mesmo `engine.js`, nas 16 sessões s5 do DMD (detecção, com anotação) e nas 17 sessões s1 (falso alarme em motoristas acordados, direção real).
- No navegador: o app, rodando no Chrome headless mudo, recebe 14 trechos reais pela câmera falsa: DMD s5, UTA-RLDD alerta e sonolento, e NITYMED.
- Teste independente em sono real (26/10): o mesmo motor, com a configuração final e sem o LSTM, em 24 pessoas da UTA-RLDD que não entraram no ajuste (todas as dos folds oficiais 2 e 4, regra fixada antes de rodar), com o vídeo acordado e o sonolento de cada uma. A calibração é a do app, nos 10 s iniciais de cada vídeo; numa variante, o vídeo sonolento usa a calibração do acordado. Sinais do mesmo Face Landmarker da PWA, em todos os quadros.
- Sensibilidade dos pesos (26/10): nos mesmos sinais do DMD, só os números do nível mudam (pontos, tetos, decaimentos e limiares), uma mudança por vez e em 300 combinações sorteadas. A configuração sem mudança reproduz a validação do DMD.
- Comparação (27/10): nas mesmas 24 pessoas do teste independente, a AUC por vídeo do app foi posta ao lado da dos modelos do Exp. 5b (C, treinados no DMD, e B, treinados na própria UTA-RLDD) e da regra do rótulo do DMD (`src/experiments/comparar_app_uta.py`).

7. Resultados

7.1 Exp. 1 (`results/exp1_intra.md`, `results/exp1_intra.csv`; log `results/logs/exp1_20260920-182858.log`)

3 classes, % (média ± dp populacional nos 5 folds):

Modelo	BSA	Acur. bal.	F1 macro	AUC	VA
Acaso (classe majoritária)	44,4 ± 2,4	n/a	n/a	n/a	33,3
LogReg	49,4 ± 4,3	49,7 ± 3,0	48,5 ± 3,6	68,9 ± 5,5	50,7 ± 7,6
SVM-RBF	53,0 ± 3,8	56,2 ± 4,5	54,2 ± 3,9	69,9 ± 5,1	54,0 ± 4,0
RandomForest	54,5 ± 9,3	57,8 ± 7,9	56,0 ± 9,1	73,5 ± 6,8	57,3 ± 7,2
LSTM (50 ép.)	50,8 ± 8,9	53,1 ± 6,7	51,8 ± 7,8	68,6 ± 8,2	57,2 ± 7,5
CNN1D (50 ép.)	48,0 ± 6,8	51,4 ± 5,2	50,0 ± 6,4	68,4 ± 6,1	55,0 ± 8,2
Ref. HM-LSTM (Ghoddoosian et al., 2019, Tab. 2)	54,0	n/a	n/a	n/a	65,2
Ref. LSTM (idem)	52,8	n/a	n/a	n/a	61,4
Ref. humanos (idem)	n/a	n/a	n/a	n/a	57,8

VA por fold (RF: 54,5 / 69,4 / 50,0 / 61,1 / 51,5; LSTM: 45,5 / 63,9 / 55,6 / 66,7 / 54,5; HM-LSTM: 64 / 61 / 70 / 64 / 67) mostra variância entre folds da ordem de 15 a 20 pp, própria de 58 sujeitos. Esquemas binários (BSA / VA do RF): B1 87,4 / 82,2 (acaso por sequência 81,4); B2 66,5 / 70,1 (LogReg VA 73,6); B3 86,9 / 85,5 (CNN1D BSA 85,2, AUC 93,8). Sensibilidade a épocas: LSTM com 15 épocas, BSA 50,6 / VA 52,7; CNN1D com 15 épocas, 49,8 / 55,1. Com 50 épocas, a acurácia de treino chega a cerca de 0,90 a 0,93, enquanto a BSA em sujeitos não vistos fica em cerca de 0,50 (sobreajuste aos sujeitos do treino). Modelo exportado: LSTM do fold 3 (`models/blink_temporal.tflite`, 101,8 KB, 5.324 parâmetros; latência no Mac, p50 de 0,033 ms).

Leitura. O RF empata com o HM-LSTM na unidade por sequência (54,5 × 54,0), mas fica 7,9 pp abaixo por vídeo (57,3 × 65,2), no nível do julgamento humano (57,8). O artigo original usa uma rede treinada de ponta a ponta com regressão dos níveis KSS e votação diferente; a diferença por vídeo é coerente com a literatura de sonolência real e com a instabilidade dos modelos temporais pequenos.

7.2 Exp. 2 (`results/exp2_leakage.md`, `results/exp2_leakage_plot.csv`; log `results/logs/exp2_20260920-183128.log`)

3 classes, % (média ± dp entre 3 sementes em (i) e (ii) e entre os 5 folds em (iii)):

Partição	RF BSA	RF acur. bal.	RF AUC	RF VA	LSTM BSA	LSTM VA	vídeos / sujeitos do teste vistos no treino
(i) por janela	99,5 ± 0,0	99,6 ± 0,0	100,0	n/a	87,3 ± 0,7	n/a	97,1 % / 100 %
(ii) por vídeo	47,2 ± 1,4	52,5 ± 0,7	67,9	52,8 ± 1,2	45,1 ± 0,6	46,2 ± 2,3	0 % / 98,3 %
(iii) por sujeito	54,2 ± 8,7	57,4 ± 7,5	73,4	55,7 ± 6,6	49,2 ± 8,8	50,8 ± 13,7	0 % / 0 %
Inflação (i) – (iii)	+45,3 pp	+42,1 pp	+26,6 pp	n/a	+38,1 pp	n/a	
(ii) – (iii)	–7,0 pp	–5,0 pp	–5,5 pp	–2,8 pp	–4,1 pp	–4,6 pp	

No cenário do Exp. 5b (`results/exp5b_robustez.md`, seção 4; janelas de 10 s, B3), com as mesmas características:

Modelo	Características	Acur. bal. por sujeito	Acur. bal. com partição aleatória	Inflação
RF	centradas	74,2	86,8	+12,6 pp
RF	brutas	62,9	77,5	+14,7 pp
RL	centradas	72,0	73,1	+1,2 pp
RL	brutas	68,1	69,0	+0,9 pp

Leitura.

- O que infla é o mesmo vídeo nos dois lados. Na partição por janela, sequências vizinhas dividem 28 das 30 piscadas, então o teste vê quase as mesmas sequências do treino, e o RF vai de 54,2% a 99,5%.
- Reconhecer a pessoa não infla nada aqui. Na partição por vídeo, a pessoa aparece no treino com os outros dois vídeos, e o resultado fica *abaixo* da partição por sujeito (–7,0 pp). Uma explicação provável, que não isolamos, é que o modelo associa o padrão de piscadas da pessoa a rótulos que não são os do vídeo de teste (cada sujeito tem exatamente um vídeo por classe).
- O vazamento pesa nos modelos flexíveis. No cenário do Exp. 5b, a partição aleatória infla o RF em 12,6 pp, efeito da mesma ordem da troca do treino real pelo atuado (9,0 pp de acurácia balanceada), e quase não muda a RL (1,2 pp).
- Não é a explicação dos 90% da literatura. Os 90% do NTHU-DDD foram medidos com outras pessoas no teste; a distância até a UTA-RLDD não se explica por esse vazamento. A parte atuado → real é medida no Exp. 5b (seção 7.6).

7.3 Exp. 3 (`results/exp3_eye_state.md`, `results/exp3_eye_state.csv`, `results/exp3_strat_conditions.csv`; log `results/logs/exp3_eye_state_train.log`)

Acurácia média ± dp (ddof=1) de 5 folds, %:

Treino → Teste	Acurácia	Acur. bal.	AUC	Acaso
A: MRL → MRL (sujeitos não vistos)	94,1 ± 3,4	94,2 ± 3,5	98,6 ± 1,3	60,3
B: MRL → CEW patch (5 folds)	79,0 ± 8,5	78,7 ± 8,6	93,2 ± 4,7	50,8
B: MRL → CEW crop (5 folds)	80,6 ± 10,3	80,3 ± 10,5	93,5 ± 4,9	50,8
B: modelo final (37 sujeitos) → CEW patch / crop	85,7 / 90,0	85,5 / 89,9	96,8 / 97,6	50,8
C: CEW patch → MRL (5 folds)	68,1 ± 1,9	68,4 ± 1,9	84,2 ± 2,8	50,6
C: CEW crop → MRL (5 folds)	67,1 ± 1,8	67,4 ± 1,8	83,6 ± 3,1	50,6

Treino → Teste	Acurácia	Acur. bal.	AUC	Acaso
D: CEW → CEW patch / crop (faces não vistas)	94,7 ± 1,1 / 94,5 ± 1,3	94,7 / 94,4	98,9 / 98,8	50,8

Por condição (PP3), acurácia / acurácia balanceada:

Condição do MRL (n)	A: MRL → MRL (fora da amostra)	C: CEW patch → MRL (média dos 5 modelos)
com óculos (24.001)	88,8 / 88,5	65,2 / 61,1 (AUC 65,1)
sem óculos (60.897)	96,1 / 96,0	69,3 / 71,8 (AUC 93,4)
iluminação ruim (53.630)	94,4 / 94,3	67,1 / 63,8
iluminação boa (31.268)	93,5 / 92,6	69,9 / 75,1
reflexo grande (12.709)	86,7 / 84,2	62,5 / 65,7
sem reflexo (66.227)	95,4 / 95,5	67,7 / 64,8
sensor RealSense / IDS / Aptina	93,5 / 96,4 / 98,3 (bal. 93,5 / 91,9 / 93,7)	bal. 60,9 / 84,3 / 97,1

Referência (só o fold 1, `results/exp3_mobilenetv3.csv`): MobileNetV3-Small 0,75 (583.593 parâmetros) 95,9 % / AUC 99,2, contra EyeNet 91,2 % / 97,3 nos mesmos sujeitos de teste.

Leitura. Dentro de cada base, a tarefa é quase resolvida nos dois domínios (de 94 % a 95 %). A transferência é assimétrica: MRL → CEW perde de 4 a 15 pp (e o modelo com todos os 37 sujeitos recupera parte: 90,0 % no crop), enquanto CEW → MRL perde cerca de 27 pp: 2.423 faces RGB de baixa resolução não cobrem a variedade de sensores infravermelhos, óculos e reflexos do MRL. Óculos é a condição dominante: no sentido CEW → MRL, a AUC despenca de 93,4 (sem) para 65,1 (com). O fold 3 de A é o pior tanto dentro do MRL (90,1 %) quanto MRL → CEW (66,0 / 64,7 %), o que explica o desvio de 8 a 10 pp no sentido MRL → CEW. Os estratos IDS e Aptina têm 95,2 % e 86,4 % de olhos abertos; por isso a acurácia balanceada é a métrica reportada neles.

7.4 Exp. 4: custo no celular (`results/exp4_tflite_eval.csv`, `results/exp4_desktop_latency.csv`, `results/exp4_phone_latency.md`)

Queda causada pela quantização (o conjunto MRL não é teste cego para o modelo final; serve só para a diferença):

Conjunto	n	Keras acc	fp32 acc	int8 acc	int8 – Keras	Keras AUC	int8 AUC
MRL completo	84.898	98,5	98,5	98,5	–0,03 pp	99,9	99,9
CEW patch (cego)	4.846	85,7	85,7	85,6	–0,10 pp	96,8	96,3
CEW crop (cego)	4.846	90,0	90,0	89,7	–0,31 pp	97,6	97,2

Tamanho e latência em lote 1 no desktop (`results/exp4_desktop_latency.csv`; Mac arm64, TF 2.21, 1 thread, p50 / p95):

Modelo	Tamanho	p50 / p95
EyeNet fp32	248,2 KB	0,067 / 0,070 ms
EyeNet int8 (E/S uint8)	72,1 KB	0,060 / 0,064 ms
LSTM de piscadas fp32	101,8 KB	0,033 / 0,045 ms

Com 4 threads, a latência *aumenta*: os modelos são tão pequenos que o custo de chamada domina. O número do desktop não deve ser extrapolado para o celular.

Celular. O app 2.1 foi medido nos dois aparelhos, em 3 execuções de 60 s em cada. No iPhone 17 Pro (iOS 26.6.1, Chrome 156), em 06/11: de 11 a 12 ms por quadro (p50), mediana de 11 ms, com 60 quadros por segundo; o Face Landmarker levou 9 ms e a CNN dos dois olhos, 2 ms. No Galaxy S23 Ultra (Android 16, Chrome 156), em 05/11: de 39,1 a 40,1 ms por quadro, mediana de 39,5 ms, cerca de 23 quadros por segundo; o Face Landmarker levou 21,9 ms e a CNN dos dois olhos, 16,1 ms (medianas dos p50 das execuções). O iPhone registra milissegundos inteiros. As condições de cada sessão estão em `results/phone/NOTAS.md`. Em 27/09, o app 1.0 tinha sido medido no iPhone em 2 execuções (11 e 23 ms por quadro), que ficam fora das médias. A tabela por execução (aparelho, sistema, navegador, versão do app, quadros por segundo e p50 e p95 de cada estágio) é gerada por `tools/import_phone_benchmark.py` a partir dos CSV brutos por quadro de `results/phone/`: `results/exp4_phone_latency.md`.

A versão 1.0 deu falso alarme. Numa execução de 27/09, com um dos autores acordado diante da câmera, a lógica antiga acusou PERCLOS de 25,8% e manteve o alarme ligado em 63,4% dos quadros (`results/phone/benchmark_pwa_2026-09-27T22-41-35-365Z.json`). Isso motivou a reescrita do detector (seção 7.8).

7.5 Exp. 5a: validação do extrator (`results/exp5a_validacao.md`)

47 sujeitos com par confirmado e 141 vídeos. Diferença oficial − nosso, com IC 95% por bootstrap sobre sujeitos; positivo = o nosso perde:

Comparação	Oficial	Nosso	Diferença (pp)	p (permutação)
Custo de trocar o extrator, 3 classes, acur. bal.	58,9	57,0	+2,0 [−4,8; +8,5]	0,555
Idem, VA	58,9	56,7	+2,1 [−6,4; +9,9]	0,734
Idem, B3, acur. bal.	85,5	85,0	+0,5 [−6,4; +7,2]	0,904
Mesmo extrator no treino e no teste (5 folds), B3, acur. bal.	83,1	89,8	−6,7 [−12,9; −1,8]	0,029
Idem, 3 classes, acur. bal.	54,6	56,3	−1,7 [−10,4; +5,7]	0,712

Leitura. O custo de trocar o extrator não se distingue de zero. Com cada extrator no próprio treino e teste, o nosso é melhor em B3 nos 5 folds, mas, deixando um sujeito de fora por vez, a diferença não se distingue de zero (−4,5 [−11,0; 0,6]); em 3 classes, ela também não se distingue de zero. O IC largo não prova equivalência, mas não há perda detectável ao trocar de extrator.

As variantes com bordas da piscada no limiar custam mais (+9,3 pp), o que confirma a escolha da variante "estendida", fixada antes do experimento.

Duas pastas da UTA-RLDD não têm sujeito oficial (F1_12, F5_49). Por isso os `.npy` têm 58 sujeitos.

7.6 Exp. 5b: transferência DMD → UTA-RLDD, PP1 (`results/exp5b_transferencia.md`, `results/exp5b_robustez.md`)

Esquema B3 (KSS 0 × 10), variante principal. AUC × 100 e acurácias em %, com IC 95% por bootstrap sobre sujeitos:

Métrica	Modelo	(A) DMD → DMD	(B) UTA → UTA	(C) DMD → UTA	Queda PP1 (B − C), pp
AUC por janela	RF	82,4 [73,6; 89,7]	80,1 [76,3; 83,8]	69,2 [63,7; 74,3]	10,9 [6,7; 15,7]
AUC por janela	RL	83,5 [76,1; 88,9]	74,4 [69,7; 78,4]	64,5 [58,1; 70,9]	9,8 [3,7; 16,0]
Acur. bal. por janela (0,5)	RF	76,4 [68,3; 83,7]	74,2 [70,9; 77,6]	65,2 [61,7; 68,6]	9,0 [5,8; 12,2]
AUC por vídeo	RF	n/a	92,4 [87,9; 96,2]	80,5 [73,0; 87,2]	11,9 [5,6; 18,8]
AUC por vídeo	RL	n/a	89,0 [82,2; 94,9]	76,0 [67,8; 84,7]	13,0 [5,8; 20,8]
Acurácia por vídeo (0,5)	RF	n/a	85,8 [80,0; 91,7]	73,3 [67,5; 79,2]	12,5 [5,0; 19,2]

Amostra:

- DMD: 510 janelas (87 alertas, 423 sonolentas) de 13 sujeitos;
- UTA B3: 12.487 janelas avaliáveis e 120 vídeos lógicos de 60 sujeitos.

Controles da queda B − C da AUC por janela (Tabela II do artigo; pontos de AUC, IC 95%). Na configuração principal, a referência da UTA-RLDD é o último terço do vídeo alerta:

Variação	RF	RL
Principal	10,9 [6,7; 15,7]	9,8 [3,7; 16,0]
IC com os motoristas do DMD reamostrados (C treinado de novo)	[5,7; 19,5]	[1,9; 18,1]
Referência no vídeo de pouca vigilância	2,3 [−2,5; 6,8]	7,6 [3,0; 12,5]
Sem centragem	2,1 [−1,2; 5,8]	7,3 [3,0; 11,7]
Contraste KSS 8 e 9 × 6 e 7 (dois vídeos fora da referência)	1,2 [−3,0; 5,8]	4,6 [−0,2; 9,7]
DMD: referência na s2	9,0 [5,5; 13,2]	5,4 [0,3; 10,9]
UTA-RLDD: referência no vídeo de pouca vigilância, por vídeo	−2,3 [−9,1; 4,3]	8,4 [3,4; 13,8]
B treinado com 13 sujeitos (mediana de 20 sorteios, sem IC)	9,3	7,0

Leitura.

- A RL perde em todas as formas de normalizar: de 5,4 a 9,8 pontos de AUC por janela, sempre com IC acima de zero.
- No RF, a queda depende da normalização. Na UTA-RLDD, as janelas alertas saem do mesmo vídeo usado como referência, e o RF treinado nela aproveita essa semelhança. Com a referência no vídeo de pouca vigilância ou sem centragem, a AUC de B no RF cai de 80,1 para 68,4 e 69,4, e a queda fica de 2,1 a 2,3, sem diferença detectável. Num app, a calibração e a sonolência acontecem na mesma sessão, e essa vantagem de B não se repetiria.
- O achado mais firme é a intensidade. O modelo do DMD erra sobretudo ao chamar de alerta a sonolência real: reconhece 82,0% das janelas alertas e só 48,4% das sonolentas no limiar 0,5; no limiar calibrado no DMD (0,662), 88,7% e 37,0%. Nas janelas sonolentas, o maior fechamento mediano é de 0,97 s no DMD e de 0,17 s na UTA-RLDD, e o PERCLOS mediano, de 0,208 contra 0,040. A sonolência atuada é mais extrema, em parte por construção: as janelas sonolentas do DMD são as que contêm um evento anotado.
- O volume do treino explica pouco. Com B treinado em só 13 sujeitos da UTA-RLDD por fold, como no DMD, a AUC de B fica em 78,6 (RF) e 71,5 (RL), e a queda continua (9,3 e 7,0).
- Reamostrar também os motoristas do DMD alarga o IC da queda principal, que continua acima de zero.
- Tirar o alerta do DMD da direção em movimento (s1) piora a transferência (AUC de C de 69,2 para 58,6).
- Sensibilidades. Nas variações de janela (5 e 15 s), de alerta e de referência no DMD e na exclusão do motorista em que o detector falhou, o IC da queda do RF fica acima de zero; contando a principal e a sem centragem, são 7 de 8 variantes.
- O bocejo não transfere: discrimina no DMD e quase não aparece na UTA-RLDD.

7.7 Exp. 6: noite, PP3 (`results/exp6_noite.md`)

Base / grupo	Detecção de rosto, média por vídeo [IC 95%]	SNR rápida do EAR, mediana [IC 95%]	Ruído rápido
NITYMED (noite, carro em movimento)	0,9915 [0,9875; 0,9948]	7,2 [6,4; 7,9]	0,0084
UTA-RLDD	0,9977 [0,9940; 0,9996]	21,5 [18,3; 23,5]	0,0037
DMD s5 (dia, parado, encenado)	0,9978 [0,9958; 0,9995]	23,1 [16,1; 27,9]	0,0046
DMD, direção segura, carro parado	0,9989 [0,9977; 0,9997]	13,6 [12,0; 16,9]	0,0059
DMD, direção segura, carro em movimento	0,9965 [0,9935; 0,9987]	8,7 [6,2; 10,8]	0,0097

Comparações da SNR rápida:

- Noite – DMD em movimento: –1,6 [–3,7; +1,1], com IC que inclui zero.
- No mesmo motorista do DMD, o movimento muda a SNR rápida em –5,4 [–6,6; –3,5] (11 sujeitos).

Taxa de disparo no limiar 0,5, com características brutas: % das janelas de 10 s marcadas como sonolentas, com IC 95%.

Detector	UTA KSS 0 (acordados)	DMD parado (alerta)	DMD em movimento (alerta)	UTA KSS 10	NITYMED microssono	NITYMED bocejo
RF do DMD (Exp. 5b)	26,0 [21,1; 31,1]	45,7	42,9	52,2	44,7	73,0
RF da UTA-RLDD (B3)	43,6 [38,7; 48,8]	69,1	77,1	69,4	83,5	89,5
Regra por sinais (fechamento de 0,5 s ou mais ou bocejo)	2,6	14,9	23,8	24,1	15,0	61,7

Regra × modelos no mesmo ponto de operação (`results/exp5b_robustez.md`, seção 5). Para cada modelo, o limiar é o que dá o mesmo falso alarme da regra (2,6%) nas janelas alertas do B3; esse limiar usa o rótulo do teste, então a tabela é só um diagnóstico:

Detector	Janelas sonolentas encontradas (%)
Regra (fechamento de 0,5 s ou mais ou bocejo)	24,1
RL do DMD (C), características centradas	24,7
RF do DMD (C), características centradas	16,4

Detector	Janelas sonolentas encontradas (%)
RL do DMD (C), características brutas	19,2
RF do DMD (C), características brutas	15,3
RL da UTA-RLDD (B), características centradas	27,3
RF da UTA-RLDD (B), características centradas	24,2

Leitura.

- A perda noturna está no sinal, não na captura. A queda na detecção de rosto é pequena; o que cai é a qualidade do sinal do EAR. Uma perda do mesmo tamanho já aparece de dia com o carro em movimento, no mesmo motorista. Com estes dados, a perda de sinal acompanha a condução real e não pode ser atribuída à escuridão por si só.
- Os modelos leem ruído como sonolência. O modelo da UTA lê o ruído do EAR como sonolência: se o `ear_dp` fosse o típico do alerta, o disparo nos microssonos cairia de 83,5% para 64,5%.
- A regra não é mais precisa que os modelos. No limiar 0,5, os RF disparam em muitas janelas de pessoas acordadas, mas esse limiar é arbitrário. Com o mesmo falso alarme da regra, a RL do DMD centrada acha tantas janelas sonolentas quanto ela; os modelos com características brutas acham menos. A regra fica na mesma curva, sem treino e com cada alarme explicável.
- Nenhum dos dois resolve o carro em movimento. Lá, com o limiar calibrado no treino, o RF do DMD dispara em 21,9% das janelas de motoristas acordados, e a regra, em 23,8%.
- Sem classe alerta noturna, não há acurácia. Nenhum limiar pode ser calibrado para a noite.
- O NITYMED não entra na PP1. A autenticidade dos comportamentos dele não é documentada.

7.8 App de demonstração, PWA 2.1 (`results/app_validacao_dmd.md`, `results/app_validacao.md`, `results/app_validacao_uta.md`, `results/app_sensibilidade_pesos.md`, `app/pwa/README.md`)

Medida	Resultado	Onde
Falso alarme, direção real com motoristas acordados (DMD s1, 17 sessões, 63,3 min)	3,3% do tempo em vermelho; 16 de 17 sessões sem alarme. O caso restante é gA_5 (55,8% em vermelho): olhar para baixo é lido como olho fechado	motor offline
Mesma medida com a lógica 1.0 (PERCLOS; sem LSTM)	55,6% do tempo em vermelho	motor offline
UTA-RLDD, vídeos alertas (3 pessoas, 3 min cada)	100% do tempo em verde, 0 alarmes, 0 avisos	navegador
Estado do olho por quadro (DMD s5)	kappa 0,938 (offline, 16 sessões) e 0,902 (navegador, 4 sessões)	ambos
Fechamentos de 1 s ou mais (DMD s5)	revocação 0,920 e precisão 0,748 (offline); 31 de 34 no navegador	ambos
Bocejo (DMD s5)	revocação 0,638 sem a mão e 0,026 com a mão na boca (offline); 6 de 24 no navegador, nenhum com a mão	ambos
UTA-RLDD, vídeos sonolentos (3 pessoas)	só 1 de 3 chegou ao vermelho (Fold3/31: 93,5% do tempo); os outros dois ficaram 100% verdes	navegador
Cabeça	sem revocação medida: o DMD não anota cabeceio. Há só o teste sintético (0 eventos falsos com a cabeça parada) e casos isolados	navegador
Sensibilidade dos pesos (300 combinações sorteadas)	falso alarme na direção real de 1,7% a 4,9% do tempo e vermelho na sonolência encenada de 56,2% a 72,9% (percentis 5 e 95); 291 das 300 mantêm o falso alarme até 5% e a sonolência encenada acima de 50%. O que mais pesa: o limiar de 70 e o teto de 60 pontos dos fechamentos	motor offline

Teste independente em sono real (`results/app_validacao_uta.md`): 24 pessoas da UTA-RLDD fora do ajuste, um vídeo acordado (KSS de 1 a 3) e um sonolento (KSS 8 e 9) de cada, 8,2 h avaliadas.

Medida	Calibração no próprio vídeo	Calibração do vídeo acordado
Acordados com algum alarme	2 de 24 (0,46% do tempo em vermelho; 3 alarmes em 4,0 h)	igual
Acordados que chegam ao amarelo	5 de 24	igual

Medida	Calibração no próprio vídeo	Calibração do vídeo acordado
Sonolentos que chegam ao amarelo	17 de 24	19 de 24
Sonolentos que chegam ao vermelho	15 de 24	17 de 24
Pessoas com mais tempo fora do verde no vídeo sonolento (mais / igual / menos)	16 / 7 / 1	19 / 5 / 0
AUC do % do tempo fora do verde, sonolento × acordado [IC 95%]	0,812 [0,705; 0,918]	0,855 [0,760; 0,948]
AUC do nível médio [IC 95%]	0,839 [0,736; 0,935]	0,891 [0,811; 0,965]

Nas mesmas 24 pessoas, a AUC por vídeo dos outros detectores (`results/app_comparacao_uta.md`):

Detector	AUC por vídeo [IC 95%]
app 2.1, % do tempo fora do verde (sem treino nesta base)	0,812
RF treinado no DMD (C), com centragem	0,811 [0,686; 0,915]
regra do rótulo do DMD (fechamento de 0,5 s ou mais ou bocejo; sem treino)	0,853 [0,754; 0,944]
RF treinado na própria UTA-RLDD (B), com a centragem pelo vídeo acordado	0,953 [0,898; 0,997]
RF treinado na própria UTA-RLDD (B), sem centragem	0,806 [0,686; 0,927]

Leitura.

- O app mede sinais visíveis, não o estado interno. Quem relata sono sem mostrar sinais não é acusado.
- A regra foi escolhida por ser explicável. No mesmo falso alarme, ela acha tantas janelas sonolentas quanto a RL do DMD (seção 7.7), sem treino e com o porquê de cada alarme.
- Os pesos do nível são escolhas de projeto, não ajustes em dados de sonolência real, e a validação no DMD usa os mesmos dados em que as regras foram escolhidas. Variar os pesos em até 30% e os limiares em até 10 pontos quase não muda o comportamento nesses dados (origem de cada número: `app/pwa/README.md`, seção 13).
- O teste na UTA-RLDD não teve ajuste. Com sono real declarado, o app saiu do verde em 17 de 24 sonolentos e em 5 de 24 acordados. Ele reage a sinais visíveis, não ao sono declarado: 7 sonolentos ficaram verdes, e em 6 deles o app não viu nenhum fechamento de 0,5 s ou mais, bocejo ou queda da cabeça.
- Calibrar já com sono atrapalha: em 7 dos 24 vídeos sonolentos, os olhos ficaram fechados em mais de 10% da calibração (e em 8 houve algum aviso de calibração); nos acordados, isso aconteceu em 2. Com a calibração do vídeo acordado, a AUC sobe para 0,855.
- O app, sem treino, fica no nível do RF treinado no DMD e perto da regra do rótulo, que é a base dos seus sinais de olho. O RF treinado na própria UTA-RLDD só fica bem acima com a centragem pelo vídeo acordado, o atalho discutido no Exp. 5b; sem ela, fica no nível do app.
- Essas pessoas estavam sentadas, sem dirigir. O falso alarme em movimento continua medido só pela direção real do DMD.
- A amostra do navegador é pequena (cerca de 40 min).
- O app funciona sem internet com `app/pwa/vendor/` completa; com internet, a biblioteca do MediaPipe envia telemetria de uso a um servidor do Google depois de cerca de 60 s, sem quadros de vídeo (`README.md`, seção 9).
- Limites conhecidos: `app/pwa/README.md`, seção 10.

8. Respostas às perguntas de pesquisa

- PP1. Sim, há queda, e ela não vem do extrator (Exp. 5a). Treinar em sonolência encenada custa de 5,4 a 9,8 pontos de AUC por janela na RL em todas as formas de normalizar; no RF, a perda de 10,9 da configuração principal depende da referência da normalização e some com outra referência ou sem centragem (Exp. 5b).
  - O achado mais firme é a intensidade: o modelo encenado reconhece a maioria das janelas alertas reais, mas só 48,4% das sonolentas. A causa mais provável é a intensidade: ele aprende com eventos extremos, e a sonolência real tem fechamentos curtos e PERCLOS baixo.
  - O volume do treino explica pouco (B com 13 sujeitos mantém a queda). Com um único par de bases, a queda ainda se mistura com a câmera, o cenário e a natureza do rótulo.

    - O vazamento por janelas do mesmo vídeo infla muito a acurácia (+45,3 pp no Exp. 2; +12,6 pp no RF no cenário do Exp. 5b), mas isso não explica os 90% do NTHU-DDD, medidos com outras pessoas no teste.
- PP2. O pipeline roda no navegador dos dois celulares medidos. Os modelos próprios são pequenos (72,1 KB a CNN int8 e 101,8 KB o LSTM), e o int8 custa no máximo 0,31 pp de acurácia. Com o app 2.1, a mediana do tempo por quadro foi de 11 ms no iPhone 17 Pro (60 quadros por segundo) e de 39,5 ms no Galaxy S23 Ultra (cerca de 23 quadros por segundo), onde a CNN dos olhos leva 16,1 ms e o Face Landmarker, 21,9 ms. Não medimos bateria, aquecimento em uso longo nem aparelhos de entrada.
- PP3.
    - Óculos: é a condição que mais derruba o estado ocular entre domínios (Exp. 3).
    - Noite: a perda aparece no sinal do EAR, e uma perda do mesmo tamanho aparece de dia com o carro em movimento (Exp. 6). A noite não pode ser isolada com as bases públicas disponíveis.
    - Óculos escuros ficam sem cobertura em dado real.

9. Cronograma: planejado × realizado e o que mudou

As datas da coluna "Quando" saem dos logs de `results/logs/` (o nome de cada log traz a data e a hora da execução) e, para o celular, dos arquivos de `results/phone/`.

Fase (plano da Entrega 01)	Previsto	Realizado	Quando	Situação
F0 Planejamento e baseline	03/08 a 05/09	plano, pôster, repositório com a baseline (RF, BSA 54,7 ± 9,0) e demo de webcam	baseline em 24/08, repetida em 26/08 (`baseline_20260824-212550.log`, `baseline_20260826-090734.log`); envio da baseline em 26/08	concluída
F1 Preparação dos dados	31/08 a 27/09	UTA-RLDD completa (características oficiais e 182 vídeos), DMD (sonolência e distração), NITYMED, MRL Eye, CEW; sinais por quadro das três bases de vídeo	caches do MRL e do CEW em 20/09 (`exp3_cache_build.log`); sinais e características em 27/09 (`extract_signals_*.log`, `exp5_final_run_features.log`)	concluída no prazo, com troca de base
F2 Pipeline A e Exp. 1	14/09 a 11/10	Exp. 1 (5 modelos, 4 esquemas, BSA e VA); extrator próprio validado (Exp. 5a); janelas de 10 s	Exp. 1 em 20/09 (`exp1_20260920-182858.log`); Exp. 5a em 27/09 (`exp5a_validacao_20260927-221239.log`)	concluída antes do prazo
F3 Pipeline B	28/09 a 25/10	EyeNet (62.865 parâmetros) no MRL e no CEW, por óculos, iluminação, reflexo e sensor; MobileNetV3 como referência	20/09 (`exp3_eye_state_train.log`, `exp3_mobilenetv3.log`)	concluída antes do prazo
F4 Exp. 2 e 3 do plano (treino atuado, teste real, por condição)	12 a 25/10	Exp. 5b (DMD → UTA-RLDD) com 8 sensibilidades; Exp. 6 (noite); Exp. 2 (vazamento) e Exp. 3 (MRL ↔ CEW) como complementares; controles da queda do Exp. 5b	Exp. 2 em 20/09 (`exp2_20260920-183128.log`); Exp. 5b e 6 em 27/09 (`exp5b_transferencia.log`, `exp6_final_noite.log`); controles em 26/10 (`exp5b_robustez_20261026-2051.log`)	concluída em 27/09; os controles, pedidos pelas revisões simuladas, entraram em 26/10

Fase (plano da Entrega 01)	Previsto	Realizado	Quando	Situação
F5 Exp. 4 e consolidação	12/10 a 08/11	int8 e desktop; PWA 2.1 validada, inclusive num teste independente em sono real; app sem internet; app 2.1 medido no Galaxy e no iPhone; números conferidos	Exp. 4 desktop em 20/09 (`exp4_export_tflite.log`); validação do app em 27/09 (`app_validacao_dmd_20260927-225227.log`, `app_validacao_20260927-232519.log`, `pwa_test_engine_20260927-231003.log`); app 1.0 no iPhone em 27/09 (`results/phone/`); números refeitos em 28/09 e 06/10 (`atualizar_celular_*.log`) e em 26/10 (`results/numeros_resumo.md`); sensibilidade dos pesos e teste independente do app na UTA-RLDD em 26/10 (`app_sensibilidade_pesos_20261026-224834.log`, `app_validacao_uta_20261026-230247.log`); app 2.1 no Galaxy S23 Ultra em 05/11 e no iPhone 17 Pro em 06/11 (`results/phone/NOTAS.md`, `atualizar_celular_20261105_193550.log`, `atualizar_celular_20261106_225903.log`)	concluída
F6 Comunicação	28/09 a 16/11	artigo e pôster reescritos para DMD, NITYMED, Exp. 5a, 5b e 6 e app 2.1; artigo com 7 páginas em 06/10 e reescrito depois da banca simulada em 26/10 (8 páginas); pôster refeito em 26/10; artigo e pôster refeitos com as medições dos celulares em 05 e 06/11	`atualizar_celular_20260928_014152.log`, `atualizar_celular_20261006_161528.log`, `atualizar_celular_20261105_193550.log`, `atualizar_celular_20261106_225903.log`; `paper/numeros.tex` de 06/11	em andamento: falta a leitura final da equipe e do orientador

O que mudou em relação ao planejamento (justificativa completa em `docs/TROCA_DATASETS.md`):

1. Base atuada: NTHU-DDD → DMD, e noite pelo NITYMED. O NTHU-DDD não foi obtido: o termo exige assinatura de chefia institucional, e o prazo era 20/09. A PP1 passou a ter experimento direto (Exp. 5b), além do contraste com a literatura e da inflação medida no Exp. 2.
2. Janela: 30 s → 10 s (passo de 5 s mantido). Os trechos de direção segura do DMD duram de 10 a 26 s. A predição por vídeo continua sendo a média dos escores das janelas, como no plano.
3. Aparelho: além do Galaxy S23 Ultra, o iPhone 17 Pro. O Galaxy é de um colega e só pode ser medido na PUC; o iPhone é de um dos autores. O app 1.0 foi medido no iPhone em 27/09 (2 execuções), e o app 2.1, nos dois aparelhos, com 3 execuções em cada: no Galaxy em 05/11 e no iPhone em 06/11.
4. Exp. 3 = estado ocular MRL ↔ CEW, e não mais o NTHU-DDD por condição. A CNN própria substituiu a MobileNetV3 como modelo principal, por ser 9× menor e exportável para int8.
5. App: a lógica de alarme mudou. A 1.0 (PERCLOS e LSTM) deu falso alarme com uma pessoa acordada e ficou 55,6% do tempo em vermelho na direção real do DMD. A 2.1 alarma por sinais visíveis e funciona sem internet. O app Android nativo mantém a 1.0 e não foi compilado.
6. Ambiente: dois ambientes Python (`.venv` e `.venv-mp`). O MediaPipe que funciona neste Mac é incompatível com o TensorFlow.
7. Leitura da PP1 (26/10). Os controles do Exp. 5b mostraram que a queda do RF depende da referência da normalização. O resultado principal passou a ser a perda da RL em todas as normalizações e a diferença de intensidade entre o sono encenado e o real.

10. Riscos e próximos passos até 16/11

Risco	Impacto	Mitigação
O orientador não aprovar a troca de bases	artigo e pôster precisariam de outro enquadramento	resolvido: o orientador autorizou a troca verbalmente (registrado em 04/10/2026; `docs/TROCA_DATASETS.md`)
Medições curtas (60 s), só em aparelhos de topo	conclusão restrita na PP2	3 execuções por aparelho; reportar mediana e extremos entre as execuções, sem extrapolar; o artigo diz que não medimos bateria, aquecimento em uso longo nem aparelhos de entrada

Risco	Impacto	Mitigação
Rede da PUC isola os aparelhos ou não tem internet	demonstração sem app	Acesso Pessoal do iPhone com o Mac e o celular; app sem internet com `app/pwa/vendor/` (conferir na véspera com `bash tools/baixar_dependencias_app.sh --conferir`)
Artigo passar de 8 páginas	fora da regra	hoje está com 8: qualquer acréscimo precisa de um corte; conferir as páginas depois de cada compilação
Artigo ou pôster voltarem a divergir dos resultados depois de alguma nova rodada	inconsistência visível	números só por macros; depois de qualquer mudança em `results/`, rodar `bash tools/atualizar_celular.sh` (refaz números, artigo e pôster e confere cada número)
Rostos das bases no repositório público	violação de licença	`.gitignore` exclui dados e a figura interna com rostos do DMD; a figura de amostras só tem o MRL Eye; conferir `git status` antes do push
`results/exp5b_predicoes.csv` (32 MB) no GitHub	repositório pesado	abaixo do limite de 100 MB por arquivo; é a fonte dos IC do Exp. 5b. Mantido versionado
Som do alarme no iPhone (política de áudio do iOS)	demonstração sem som	"Testar som" antes, volume de mídia no máximo (`docs/GUIA_EQUIPE.md`, seção 8)
Telemetria do MediaPipe com internet	dúvida sobre privacidade	nota no `README.md` (seção 9): sem quadros de vídeo; sem internet, nada sai do aparelho

Próximos passos, com responsável sugerido conforme a divisão do plano:

1. Feito (04/10). O orientador autorizou a troca de bases verbalmente; registro em `docs/TROCA_DATASETS.md`.
2. Feito (26/10). Controles do Exp. 5b, reescrita do artigo depois da banca simulada, app sem internet, sensibilidade dos pesos do app e teste independente do app em sono real na UTA-RLDD.
3. Feito (05 e 06/11). App 2.1 medido no Galaxy S23 Ultra (05/11) e no iPhone 17 Pro (06/11), com 3 execuções de 60 s em cada; `bash tools/atualizar_celular.sh` refez tabela, figura, números, artigo e pôster. Para repetir: `docs/GUIA_EQUIPE.md`, seção 1.
4. Até 09/11 (Entrega 02, adiada de 31/10). Este relatório lido pelos quatro e o PDF (`docs/ENTREGA02_relatorio.pdf`) enviado no Canvas; commit, tag `entrega02` e push, depois do "ok" do André (`docs/GUIA_EQUIPE.md`, seção 6) (Bruno Rodolfo).
5. Até 09/11 (artigo e pôster). Leitura final do artigo pelos quatro e pelo orientador; conferir as 8 páginas e as citações obrigatórias do NITYMED e do DMD depois de cada edição; pôster final com teste de legibilidade impresso (Paulo, com revisão de todos).
6. De 09 a 12/11. Revisão por pares de 2 artigos de outros grupos, em duplas, com o modelo de parecer de `docs/GUIA_EQUIPE.md`, seção 5; críticas ao nosso artigo incorporadas até 14/11 (todos).
7. Até 15/11. Dois ensaios da demonstração sem internet e do pitch de 60 a 90 s (`docs/GUIA_EQUIPE.md`, seções 2 e 3), com o volume em 100% só na hora (André e Bruno Sandoval).
8. 16/11. Sessão de pôsteres.
9. Trabalho futuro (registrado no artigo): repetir a transferência com outra base de sonolência real, como o DROZY, e com a referência gravada na mesma sessão; validar o app em campo, com voluntários, KSS, óculos e noite; medir a revocação da queda da cabeça. Fora do artigo: anotar óculos nos vídeos da UTA-RLDD (21 de 180 têm óculos, sem lista) e compilar o app Android com a lógica 2.1.