Detecção de Sonolência em Dispositivos Móveis: Avaliação da Generalização entre Sonolência Atuada e Real

André Luís Oliveira Ferreira da Silva, Bruno Rodolfo da Silveira,
Bruno Sandoval Ribeiro e Paulo Henrique Perin
Bacharelado em Ciência da Computação
Pontifícia Universidade Católica do Paraná (PUCPR), Curitiba, Brasil
{s.ferreira67, rodolfo.bruno, bruno.ribeiro, paulo.perin}@pucpr.edu.br

***Resumo*—Detectores de sonolência por vídeo passam de 90% de acurácia em bases *atuadas*, encenadas por voluntários, mas na UTA-RLDD, base de sonolência *real*, o modelo dos autores fica entre 54% e 65% em três classes. Medimos quanto do aprendido com sonolência atuada se transfere para a real, com o mesmo extrator e partição por sujeito. Por janela de 10 s, os modelos treinados no DMD ficam abaixo dos treinados na UTA-RLDD: a regressão logística perde de 5,4 a 9,8 pontos de AUC (área sob a curva ROC) em todas as normalizações testadas, e o Random Forest perde 10,9 na normalização principal, diferença que deixa de ser detectável com outra referência na UTA-RLDD. O modelo do DMD reconhece só 48,4% das janelas sonolentas reais, em que fechamentos de olho de 0,5 s ou mais são bem mais raros que na encenação. Misturar trechos do mesmo vídeo no treino e no teste infla a acurácia do Random Forest em até 45,3 pontos percentuais. À noite o sinal do olho piora, mas não se distingue do obtido de dia com o carro em movimento. Um protótipo web para celular, com regras explicáveis sobre olhos, bocejo e cabeça, separou *offline* os vídeos sonolentos dos acordados de 24 pessoas sentadas e fora do ajuste, com AUC de 0,812 e alarme em 15 dos 24 vídeos sonolentos e em 2 dos 24 acordados, e teve tempo mediano por quadro de 11 ms num iPhone 17 Pro e de 40 ms num Galaxy S23 Ultra.**

***Palavras-chave*—detecção de sonolência, sonolência atuada, sonolência real, generalização entre bases, vazamento entre treino e teste, UTA-RLDD, DMD, smartphone**

I. Introdução

A sonolência ao volante é um problema de saúde pública no Brasil. Um levantamento da Associação Brasileira de Medicina de Tráfego (ABRAMET) sobre registros da Polícia Rodoviária Federal (PRF) associa 27,8% dos 4,34 milhões de ocorrências em rodovias federais de 2014 a 2024 a condições de saúde do condutor, categoria que inclui o sono, mas também falta de atenção, mal súbito e uso de substâncias [1]. No anuário da PRF de 2025, a "reação tardia ou ineficiente do condutor", causa compatível com a sonolência, aparece em 10.799 sinistros [2].

Há também uma lacuna de método. Até a UTA-RLDD (*UTA Real-Life Drowsiness Dataset*), segundo seus autores, os detectores por vídeo costumavam ser avaliados em bases privadas ou *atuadas*, com sonolência encenada por voluntários [3], e só 15 dos 126 estudos revisados por Perkins et al. [4], de todas as modalidades, têm dados de estrada. Na base atuada mais usada, o NTHU-DDD [5], as acurácias publicadas vão de 73% [6] a valores entre 90% e 94% [7], [8]. Na UTA-RLDD, base de sonolência *real*, o modelo de base acerta 54% das sequências de piscadas e 65,2% dos vídeos, e pessoas que assistiram aos vídeos acertaram 57,8% [3]. Os autores da UTA-RLDD deixam em aberto se vídeos de sonolência atuada servem de treino para detectar a real [3]. A diferença mistura três fatores: o tipo de sonolência; o protocolo, já que trechos da mesma pessoa ou do mesmo vídeo nos dois lados inflam a acurácia [4] (na própria UTA-RLDD, uma CNN que classifica quadros passa de 90% em validação cruzada sobre imagens [9]); e a tarefa, que na UTA-RLDD tem três classes, uma delas intermediária. Há ainda a distância entre o computador em que os modelos são avaliados e o celular em que seriam úteis.

A pergunta central é: *quanto do desempenho obtido com sonolência atuada se mantém em sonolência real, com partição por sujeito e execução no celular?* Dela saem três perguntas de pesquisa. **PP1**: quanto se perde ao treinar com sonolência atuada e testar com sonolência real, em relação a treinar na própria base real, e quanto o vazamento entre treino e teste infla os números? **PP2**: qual o custo de executar o *pipeline* num celular, em tamanho, perda por quantização e tempo por quadro? **PP3**: a degradação é uniforme ou se concentra em condições de captura, como óculos, pouca luz, reflexos, noite e carro em movimento?

As contribuições são:

1) a medida da transferência da sonolência atuada do DMD (*Driver Monitoring Dataset*) para a real da UTA-RLDD com o mesmo extrator nas duas bases, um modelo de comparação treinado na base real, intervalos de confiança (IC) por sujeito e controles que mostram quando a queda depende da normalização por sujeito;
2) a medida do vazamento entre treino e teste com dados e modelos fixos, a reprodução do protocolo oficial da UTA-RLDD e a validação do nosso extrator contra as características oficiais;
3) a comparação do sinal do olho com o carro parado e em movimento, no mesmo motorista e com a mesma câmera, contrastada com vídeos noturnos, além da aná-

lise do estado ocular por óculos, iluminação e reflexos;
4) um protótipo de celular baseado em sinais interpretáveis (olhos, bocejo e cabeça), avaliado contra a anotação do DMD, testado em sono real em 24 pessoas fora do ajuste e com o tempo por quadro medido em dois celulares (versão 2.1 do app). Código, *logs* e resultados estão no repositório do projeto[1].

II. Trabalhos Relacionados

Sinais visuais. O PERCLOS, fração do tempo com os olhos pelo menos 80% fechados, vem de um estudo em simulador feito para a agência de segurança viária dos Estados Unidos (NHTSA) [10] e mede fechamentos lentos, não piscadas [11]. Soukupová e Čech [12] definiram o *Eye Aspect Ratio* (EAR) com seis pontos por olho. Ghoddoosian et al. [3] criaram a UTA-RLDD, descreveram cada piscada por quatro características e as modelaram com uma rede recorrente LSTM (*long short-term memory*) hierárquica e multiescala (HM-LSTM). Entre as bases atuadas estão o NTHU-DDD [5] e o DMD [13].

Protocolos e generalização. Perkins et al. [4] apontam que muitos estudos põem trechos da mesma pessoa no treino e no teste e que, em estrada, estudos comportamentais com frequência pediram sonolência encenada. Bakker et al. [14], em direção real, obtêm 92% com um módulo personalizado por motorista e 72% sem ele, e Massoz et al. [15] mostram que o resultado depende da janela (70,68% com 5 s e 94,22% com 60 s). No NTHU-DDD, Wijnands et al. [16] relatam 73,9% com sujeitos separados. Entre bases de vídeo, Xie e Xiao [17] cruzam NTHU-DDD, YawDD, UTA-RLDD e DROZY e relatam queda média de 12,8 pontos percentuais (pp), e Pradeep e AlSaafin [18] medem a perda da UTA-RLDD para o DROZY. No estado ocular, os resultados de Rahman et al. [19] caem de cerca de 99% na mesma base para 90,94% do MRL para o CEW e 67,34% do CEW para o ZJU, e Florez-Zela [20], num *preprint*, relata queda do Macro-F1 de valores entre 0,96 e 0,98 no MRL para valores entre 0,21 e 0,78 no RT-BENE, sem retreino. Xie e Xiao [17] já cruzam bases atuadas e reais; até onde sabemos, nenhum trabalho compara, com o mesmo extrator, um modelo treinado em sonolência atuada com outro treinado na própria base real, nos mesmos sujeitos de teste e com controles da normalização por pessoa.

Celulares. Wijnands et al. [16] executam uma rede 3D num Galaxy S7 em 1,1 s por inferência de 10 quadros, Jabbar et al. [21] comprimem um classificador sobre pontos faciais em até 100 KB e Dasgupta et al. [22] combinam PERCLOS, voz e toque. O MediaPipe [23], [24] entrega a malha facial em tempo real no celular, e a quantização pós-treino em 8 bits costuma ficar a menos de 2 pp da versão em ponto flutuante [25].

III. Bases de Dados

A Tabela I resume as bases e o papel de cada uma.

Por que o DMD. Não usamos o NTHU-DDD porque o termo de licença exige a assinatura de uma chefia institucional. Usamos o DMD, que é RGB como a UTA-RLDD; em contrapartida, apenas 13 motoristas encenam sonolência (3 de óculos) e não há óculos escuros.

[1]https://github.com/BrunoRodolfoo/deteccao-sonolencia

Tabela I
Bases de dados e papel de cada uma (horas medidas nos arquivos processados).

Base	O que usamos	Papel
UTA-RLDD [3]	sonolência real; 60 sujeitos, 180 vídeos (31,55 h); rótulo KSS do vídeo	teste real (Exp. 1, 2, 5a, 5b e 6)
DMD [13]	sonolência atuada e direção; 14 motoristas, 65 sessões (4,24 h); eventos anotados por quadro	treino atuado (Exp. 5b); movimento (Exp. 6)
NITYMED [26], [27]	noite, carro em movimento; 126 vídeos (1,63 h), sem classe alerta	condição noite (Exp. 6)
MRL Eye [28]	84.898 imagens de olho de 37 sujeitos, em infravermelho	estado do olho (Exp. 3)
CEW [29]	4.846 recortes de olho de fotos comuns	estado do olho (Exp. 3)

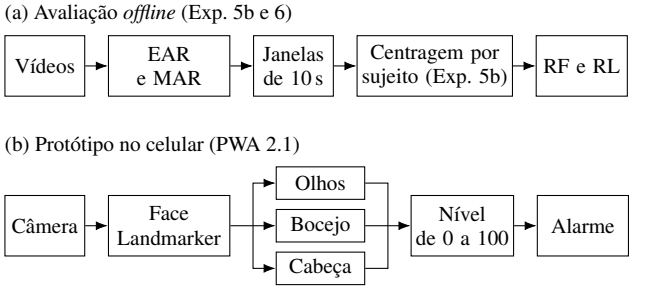


Figura 1. Cadeias de processamento. (a) Avaliação *offline* dos Exp. 5b e 6, com o mesmo extrator (Face Mesh do MediaPipe) e as mesmas características nas três bases; a centragem por sujeito vale apenas para o Exp. 5b, e o Exp. 6 usa as características brutas. (b) Protótipo no celular (aplicação web, versão 2.1): olhos, bocejo e cabeça somam pontos num nível de 0 a 100, que dispara o alarme a partir de 70.

DMD. Na sessão de sonolência (s5), o carro está parado e os comportamentos são encenados; a anotação traz o estado do olho, as piscadas e os bocejos. A classe alerta vem dos trechos de direção segura da sessão s2 dos mesmos motoristas, também com o carro parado; a s1 é de direção com o carro em movimento, e a s3 serve de referência da normalização. Os trechos de direção segura duram de 10 a 26 s, o que definiu a janela de 10 s.

NITYMED e UTA-RLDD. A página do NITYMED não diz se bocejos e microssonos foram espontâneos, e três bocejos por vídeo sugerem instrução; por isso essa base serve apenas à condição noite, nunca como evidência de sonolência real. Na UTA-RLDD, os rótulos vêm da escala de sonolência de Karolinska (KSS) [30], de 1 a 9: alerta (1 a 3), pouca vigilância (6 e 7) e sonolento (8 e 9), codificados como 0, 5 e 10. Os arquivos oficiais de características cobrem 58 dos 60 sujeitos. Nenhum quadro com rosto aparece neste artigo, por causa das licenças (DMD: CC BY-NC-ND 4.0; NITYMED: CC BY-ND 4.0) e da autorização parcial de imagem da UTA-RLDD.

IV. Método

A Fig. 1 resume as duas cadeias do trabalho.

A. Sinais, piscadas e características

Usamos o Face Mesh do MediaPipe [23], [24], na versão 0.10.21, que fornece 468 pontos do rosto por quadro. Deles calculamos o EAR [12], que soma as duas alturas do olho e divide o total pelo dobro da largura, com a média dos dois olhos, e a abertura da boca dividida pela largura (MAR). O olho conta como fechado quando o EAR fica abaixo de 0,75 vezes a mediana do EAR na referência do sujeito (Seção IV-B), e daí saem as piscadas e os fechamentos de 0,5 s ou mais. Contra a anotação quadro a quadro das 16 sessões s5 do DMD, esse detector tem F1 de piscadas de 0,749 e, por quadro, κ de Cohen de 0,773 (médias por sessão); o fator 0,75 foi fixado antes dessa validação.

Nos Exp. 1, 2 e 5a, cada piscada é descrita pelas quatro características de [3]: duração, amplitude, velocidade de abertura e frequência acumulada. Normalizadas por *z-score* do sujeito, elas formam sequências de 30 piscadas com passo 2, de modo que sequências vizinhas dividem 28 piscadas. Nos Exp. 5b e 6, a unidade é a janela de 10 s com passo de 5 s, descrita por 11 características que não dependem da taxa de quadros: PERCLOS (aqui, a fração dos quadros com o olho fechado pelo critério acima, e não a medida clássica de 80% de fechamento), taxa de piscadas, duração média da piscada, maior fechamento, número de fechamentos de 0,5 s ou mais, média e desvio do EAR, amplitude e velocidade médias das piscadas, fração do tempo em bocejo (MAR acima de 0,5 por 1 s ou mais) e fração de quadros com rosto. A nota de um vídeo é a média das notas das suas janelas.

B. Rótulos, normalização e modelos

No DMD, uma janela é sonolenta se pertence à s5 e contém um fechamento anotado de 0,5 s ou mais ou um bocejo, e é alerta se está inteira num trecho de direção segura da s2. As janelas da s5 sem evento anotado ficam de fora, porque são ambíguas. Na UTA-RLDD, o rótulo é o do vídeo, e o esquema principal, B3, compara alerta (KSS de 1 a 3) com sonolento (KSS 8 e 9), como no DMD; KSS 8 é também o nível a partir do qual a regra europeia de alerta de sonolência exige aviso [31]. Cada característica é centrada por sujeito: subtraímos a média de uma referência separada, que nunca entra na avaliação. Ela é a direção segura da s3 no DMD e o último terço do vídeo alerta na UTA-RLDD, como no código original (o texto de [3] descreve o primeiro terço). O *z-score* completo não é estimável em boa parte dos sujeitos do DMD, que têm poucas janelas de referência. Os classificadores são um Random Forest (RF) com 300 árvores e uma regressão logística (RL) com padronização, ambos com classes balanceadas, valores ausentes preenchidos pela mediana do treino e hiperparâmetros fixados antes. No Exp. 1, o RF usa 24 estatísticas de cada sequência, seis por característica, e uma LSTM de 32 unidades, seguida de uma camada densa de 16 com *dropout* de 0,2, usa a sequência bruta (Adam, 50 épocas). O estágio ocular usa uma rede neural convolucional (CNN) compacta própria, a EyeNet (diferente da homônima de [19]), com três blocos convolucionais (16, 32 e 64 filtros), 62.865 parâmetros e recortes de 48×48 em tons de cinza, treinada com Adam, aumento de dados e parada antecipada (até 12 épocas e 25.000 imagens por *fold*) e exportada em TFLite fp32 e int8.

C. Protótipo móvel

O protótipo é uma aplicação web progressiva (PWA, versão 2.1) que roda no navegador do celular, sem enviar vídeo. O Face Landmarker do MediaPipe fornece 478 pontos, 52 *blendshapes* e a pose da cabeça, e três sinais visíveis são calibrados em 10 s com a pessoa olhando para a frente:

- **olhos**: fechados quando os dois *eyeBlink* ficam altos ou quando o EAR cai abaixo de 0,75 do valor da calibração, com regras de exclusão para olhar para baixo, olhos apertados e olhar lateral. Fechamentos de 0,5 a 1 s somam pontos, e olhos fechados por 1 s ou mais (microssono, que dura de 1 a 15 s [32]; o Euro NCAP trata 1 a 2 s de olhos fechados como microssono [33]) levam ao vermelho imediatamente. O PERCLOS de 60 s conta só fechamentos de 0,5 s ou mais;
- **bocejo**: *jawOpen* ou MAR acima do repouso por 1,5 s ou mais;
- **cabeça**: queda (cabeça 18° abaixo do repouso por 0,8 s) ou cabeceio, sempre *com os olhos fechados*. Cabeça baixa com os olhos abertos conta como distração e não soma pontos.

Os eventos somam pontos que decaem com o tempo num nível de 0 a 100. O estado passa a amarelo em 40 e a vermelho em 70, com histerese, e o vermelho toca uma sirene. Os pontos de um único sinal não chegam a 70; o microssono e a cabeça caída com os olhos fechados levam direto ao vermelho. A LSTM do Exp. 1 soma no máximo 10 pontos, e a CNN do Exp. 3 não soma pontos e só roda na tela de detalhes técnicos e nas medições de tempo. Os pesos do nível são regras de projeto, não ajustadas em sonolência real, porque não há base real com esses sinais marcados ao longo do tempo; a regra dos olhos e os ajustes finais foram escolhidos nos dados da validação, e a Seção VI-E mede quanto os pesos importam. A versão 1.0, substituída, alarmava por olho fechado, por um PERCLOS que contava piscadas ou pela LSTM sozinha.

V. Protocolo Experimental

A PP1 é respondida pelo Exp. 5b, com três cenários: A, DMD→DMD, deixando um sujeito de fora; B, UTA→UTA, nos 5 *folds* oficiais; e C, DMD→UTA. A queda da PP1 é B−C. Os Exp. 1 (reprodução do protocolo oficial), 2 (vazamento) e 5a (troca de extrator) apoiam a PP1; o Exp. 4 responde à PP2; e os Exp. 3 (estado ocular) e 6 (noite e movimento), à PP3. A área sob a curva ROC (AUC, $\times100$) mede a ordenação sem depender de limiar; a acurácia balanceada usa o limiar 0,5, fixado antes, e um limiar calibrado apenas no treino. Os IC 95% vêm de *bootstrap* percentil sobre sujeitos (1.000 reamostragens), pareado na queda B−C; numa análise adicional, os motoristas do DMD também são reamostrados, e C é treinado de novo a cada reamostragem. O Exp. 5a usa também permutação pareada por sujeito. No Exp. 6, a relação sinal-ruído (SNR) do EAR é a amplitude das piscadas dividida

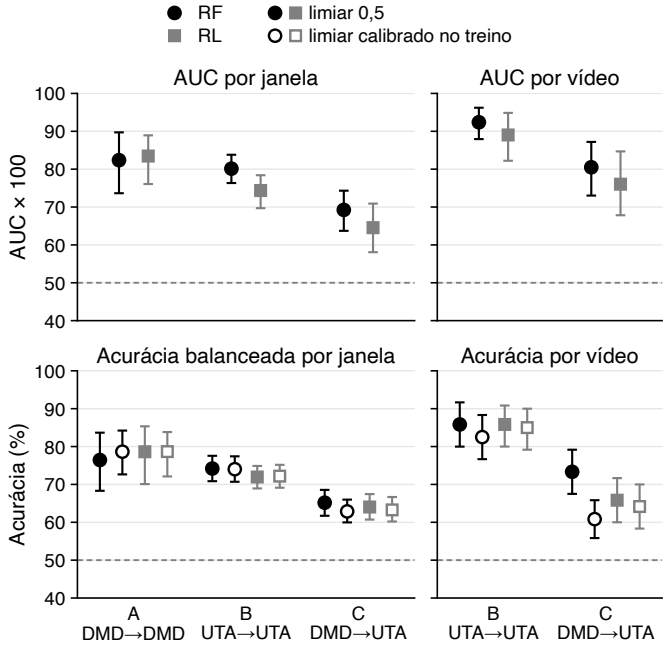


Figura 2. Exp. 5b: AUC e acurácia por janela e por vídeo nos cenários A (DMD→DMD), B (UTA→UTA) e C (DMD→UTA), com IC 95% por *bootstrap* de sujeitos; esquema B3 na UTA-RLDD (60 sujeitos, 5 *folds* oficiais) e 13 motoristas no DMD. Marcador cheio: limiar 0,5; vazado: limiar calibrado no treino. O DMD (A) não tem nível de vídeo.

pelo ruído quadro a quadro, medido como o desvio robusto em torno de uma mediana móvel de 1 s; a taxa de disparo é a fração de janelas marcadas como sonolentas e, como o NITYMED não tem classe alerta, não é acurácia. A semente é 42 em todos os experimentos, e as partições aleatórias usam 42, 43 e 44. Todo número do artigo é gerado a partir dos arquivos CSV do repositório e conferido por um segundo *script*.

VI. Resultados

A. PP1: da sonolência atuada para a real (Exp. 5b)

A Fig. 2 resume o experimento central. Na AUC por janela, o RF obtém 82,4 [73,6; 89,7] no DMD (A) e 80,1 [76,3; 83,8] na UTA-RLDD quando treinado nela (B). Treinado no DMD e aplicado à UTA-RLDD (C), fica em 69,2 [63,7; 74,3], acima do acaso. A queda B−C é de 10,9 [6,7; 15,7] pontos de AUC por janela e de 11,9 [5,6; 18,8] por vídeo (B: 92,4; C: 80,5). A RL repete o padrão, com queda de 9,8 [3,7; 16,0] por janela e de 13,0 [5,8; 20,8] por vídeo.

O modelo do DMD erra sobretudo ao chamar de alerta a sonolência real. No limiar 0,5, ele reconhece 82,0% das janelas alertas e só 48,4% das sonolentas, e o limiar calibrado no DMD (0,662) agrava o desequilíbrio (37,0% das sonolentas e 88,7% das alertas). Nas características brutas, do alerta ao sonolento, a mediana do maior fechamento vai de 0,13 a 0,97 s no DMD e de 0,07 a 0,17 s na UTA-RLDD, e a do PERCLOS vai de 0,037 a 0,208 e de 0,010 a 0,040. Parte dessa diferença vem do rótulo: as janelas sonolentas do DMD são as que contêm um evento anotado, e as da UTA-RLDD são todas as do vídeo sonolento. Por vídeo inteiro e com o mesmo detector, o maior fechamento é parecido (mediana de 2,5 s nas sessões s5 e 2,1 s nos vídeos KSS 8 e 9); o que muda é a frequência, de 5,1 fechamentos de 0,5 s ou mais por minuto na encenação e 1,0 na sonolência real.

Tabela II
Exp. 5b: queda B−C da AUC (pontos), com IC 95%, sob controles da normalização e do treino; por janela, salvo onde indicado. Na última linha, mediana de 20 sorteios, sem IC.

Variação	RF	RL
Principal	10,9 [6,7; 15,7]	9,8 [3,7; 16,0]
IC com os motoristas do DMD reamostrados	[5,7; 19,5]	[1,9; 18,1]
UTA-RLDD: referência no vídeo de pouca vigilância	2,3 [−2,5; 6,8]	7,6 [3,0; 12,5]
O mesmo, por vídeo	−2,3 [−9,1; 4,3]	8,4 [3,4; 13,8]
DMD: referência na s2	9,0 [5,5; 13,2]	5,4 [0,3; 10,9]
Sem centragem	2,1 [−1,2; 5,8]	7,3 [3,0; 11,7]
Sem centragem, por vídeo	0,2 [−5,6; 6,3]	1,2 [−5,4; 7,9]
Contraste KSS 8 e 9 × 6 e 7	1,2 [−3,0; 5,8]	4,6 [−0,2; 9,7]
B com 13 sujeitos e 510 janelas	9,5	6,7

A Tabela II mostra quanto da queda resiste aos controles. Na UTA-RLDD, as janelas alertas saem do mesmo vídeo usado como referência da normalização, e o RF treinado nela aproveita essa semelhança. Quando a referência vem do vídeo de pouca vigilância (KSS 6 e 7), que não entra na avaliação, ou quando não há centragem, a AUC de B no RF cai de 80,1 para 68,4 e 69,4, e a queda deixa de ser detectável; nessa variante, o limiar de EAR do detector continua o do vídeo alerta. Entre dois vídeos que não são a referência, a queda não é detectável em nenhum dos dois modelos, e por vídeo, sem centragem, também não. Na RL, a queda por janela fica entre 5,4 e 9,8 pontos nas quatro normalizações testadas, sempre com IC acima de zero. Com B treinado em 13 sujeitos da UTA-RLDD por *fold* e 510 janelas sorteadas, o tamanho do treino de C, a queda fica em 9,5 pontos no RF e 6,7 na RL (9,2 e 7,3 com a proporção de classes de C): o volume do treino explica pouco no RF e de um quarto a um terço na RL. Usar como alerta do DMD a direção com o carro em movimento (s1) piora a transferência (AUC de C de 69,2 para 58,6). Nas variações de janela (5 e 15 s), de alerta e de referência no DMD e sem o motorista em que o detector falhou, todas com a referência no vídeo alerta da UTA-RLDD, o IC da queda fica acima de zero, exceto na RL com janelas de 5 s (5,4 [−0,1; 10,8]).

B. Protocolo, reprodução e extrator (Exp. 1, 2 e 5a)

A Tabela III reúne os números de referência. No protocolo oficial, o RF sobre 24 estatísticas das piscadas empata com a HM-LSTM na acurácia por sequência (BSA, do inglês *blink sequence accuracy*) e fica 7,9 pp abaixo na acurácia por vídeo (VA), no nível do julgamento humano. Sem a classe intermediária (B3), chega à acurácia balanceada de 84,8% (acaso: 50%), com a mesma estrutura de referência discutida acima. Repartir as mesmas sequências ao acaso, com sequências do mesmo vídeo nos dois lados, infla a BSA em 45,3 pp no RF e 38,1 pp na LSTM; como sequências vizinhas dividem 28 das 30 piscadas, o teste vê quase as mesmas sequências do treino. A partição por vídeo, em que o treino tem os outros vídeos do mesmo sujeito com rótulos diferentes,

Tabela III

EXP. 1 E 2, TRÊS CLASSES (%), COM OS 58 SUJEITOS E 174 VÍDEOS DOS ARQUIVOS OFICIAIS: 5 *folds* OFICIAIS (MÉDIA ± DP) E AS MESMAS SEQUÊNCIAS SOB TRÊS PARTIÇÕES. BSA: ACURÁCIA POR SEQUÊNCIA DE 30 PISCADAS; VA: POR VÍDEO; N/A: NÃO SE APLICA. VALORES DE [3] PARA A HM-LSTM E OS HUMANOS. A PARTIÇÃO POR SUJEITO DO EXP. 2 USA OS 5 *folds* OFICIAIS, MAS TREINA COM AS SEQUÊNCIAS DE TESTE DOS OUTROS *folds*.

Modelo	Partição	BSA	VA
RF (24 estatísticas)	5 *folds* oficiais	$54{,}5 \pm 9{,}3$	$57{,}3 \pm 7{,}2$
LSTM (30×4)	5 *folds* oficiais	$50{,}8 \pm 8{,}9$	$57{,}2 \pm 7{,}5$
HM-LSTM [3]	5 *folds* oficiais	54,0	65,2
Humanos [3]	n/a	n/a	57,8
Classe majoritária	n/a	44,4	33,3
RF	aleatória	99,5	n/a
RF	por vídeo	47,2	52,8
RF	por sujeito	54,2	55,7
LSTM	aleatória	87,3	n/a
LSTM	por sujeito	49,2	50,8

fica *abaixo* da partição por sujeito ($-7{,}0$ pp); uma explicação provável, que não isolamos, é que o modelo associa o padrão de piscadas da pessoa a rótulos que não são os do vídeo de teste. Nesta base, o que infla a acurácia é o mesmo vídeo, e com ele o mesmo rótulo, aparecer nos dois lados. No cenário do Exp. 5b, com janelas de 10 s e duas classes, a partição aleatória de janelas infla a acurácia balanceada em 12,6 pp no RF e em 1,2 pp na RL: o vazamento pesa nos modelos flexíveis, capazes de memorizar janelas vizinhas.

Trocar o extrator dos autores (dlib) pelo nosso (MediaPipe), com o RF treinado nas características oficiais, custa 2,0 [$-4{,}8$; 8,5] pp de acurácia balanceada em três classes ($p = 0{,}555$; 47 sujeitos, os de mapeamento confirmado), diferença que não se distingue de zero. Com cada extrator no próprio treino e teste, o nosso não fica atrás (oficial menos nosso em B3: $-6{,}7$ [$-12{,}9$; $-1{,}8$] pp nos 5 *folds* e $-4{,}5$ [$-11{,}0$; 0,6] pp deixando um sujeito de fora). O IC largo não prova equivalência, mas não há perda detectável, e usamos o nosso extrator nas duas pontas do Exp. 5b.

C. PP2: custo no celular (Exp. 4)

A Tabela IV reúne as medidas, e a LSTM exportada concorda com o modelo original em Keras em 100,0% das sequências. No iPhone 17 Pro (iOS 26.6.1, Chrome 156 (iOS, motor WebKit), Face Landmarker na GPU), 3 execuções de 60 s da versão 2.1 do app somaram 10.818 quadros, 100,0% deles com rosto, e o tempo total por quadro (p50) ficou entre 11,0 e 12,0 ms nas execuções, dominado pelo Face Landmarker. No Galaxy S23 Ultra (Android 16, Chrome 156), 3 execuções da versão 2.1 ficaram entre 39,1 e 40,1 ms por quadro. O iPhone registra os tempos em milissegundos inteiros, o que limita a precisão dos estágios mais rápidos.

D. PP3: condições de captura (Exp. 3 e 6)

No estado ocular, a EyeNet atinge $94{,}1 \pm 3{,}4$% em sujeitos não vistos do MRL, $79{,}0 \pm 8{,}5$% do MRL para o CEW (média dos *folds*; 85,7% com o modelo treinado em todos os sujeitos) e $68{,}1 \pm 1{,}9$% do CEW para o MRL. Do CEW para o MRL, a AUC cai com óculos (65,1 contra 93,4 sem óculos), pouca luz (81,1 contra 89,6) e reflexo grande (69,2 contra 86,9). Essas

Tabela IV

EXP. 4. (A) MODELOS E QUANTIZAÇÃO. (B) TEMPO POR QUADRO NA PWA (VERSÃO 2.1 DO APP), EM MS: MEDIANA, ENTRE AS EXECUÇÕES DE 60 S, DO P50 E DO P95 DE CADA EXECUÇÃO, COM A CNN E A LSTM EM TODOS OS QUADROS COM ROSTO; AS MEDIANAS DOS ESTÁGIOS NÃO SOMAM A DO TOTAL.

(a) Modelos

CNN do olho: fp32 → int8 (KB)	248,2 → 72,1
Maior perda de acurácia com int8 (pp)	0,31
LSTM: parâmetros / tamanho (KB)	5.324 / 101,8

(b) *Pipeline* completo, CNN int8 (p50 / p95)

Estágio	iPhone 17 Pro	Galaxy S23 Ultra
Face Landmarker	9,0 / 11,0	21,9 / 24,8
CNN, 2 olhos	2,0 / 3,0	16,1 / 28,9
LSTM	1,0 / 1,0	0,6 / 0,7
Motor de sinais	0,0 / 0,0	0,1 / 0,2
Total por quadro	11,0 / 14,0	39,5 / 53,1

condições estão ligadas entre si e aos sujeitos, e as diferenças devem ser lidas como associações.

À noite, o rosto continua sendo encontrado em 99,15% dos quadros do NITYMED, contra 99,77% na UTA-RLDD (diferença de $-0{,}61$ [$-1{,}07$; $-0{,}14$] pp). O que cai é a qualidade do sinal (Fig. 3A): a SNR do EAR é de 7,2 [6,4; 7,9] no NITYMED, contra 21,5 na UTA-RLDD e 13,6 no DMD parado. Mas os mesmos motoristas do DMD, de dia e com o carro em movimento, ficam em 8,7. No mesmo motorista e com a mesma câmera, o movimento muda a SNR em $-5{,}4$ [$-6{,}6$; $-3{,}5$] (11 motoristas), e a diferença entre a noite e o carro em movimento não se distingue de zero ($-1{,}6$ [$-3{,}7$; 1,1]). Com estes dados, a perda de sinal acompanha a condução real, e um efeito adicional da escuridão não é detectável. Sem um trecho alerta do próprio motorista, como o da calibração do protótipo, o PERCLOS também não separa microssono de ruído de condução: com o limiar tirado do próprio vídeo, sua mediana sobe tanto nos vídeos de microssono do NITYMED (19,5%) quanto nos motoristas acordados do DMD em movimento (18,4%).

Na Fig. 3B, sem centragem, que o NITYMED não permite por falta de trecho alerta, os dois RF marcam como sonolentas de 26,0% a 43,6% das janelas de pessoas acordadas da UTA-RLDD no limiar 0,5. A regra do rótulo do DMD aplicada aos nossos sinais (fechamento de 0,5 s ou mais, com o limiar de EAR do próprio sujeito, ou bocejo) marca 2,6% ([1,4; 4,3]). Com o limiar calibrado no treino, o RF do DMD dispara ainda menos (1,7%), mas encontra menos janelas sonolentas que a regra (11,0% contra 24,1%); a RL do DMD, no limiar 0,5, marca 2,3% das janelas alertas e 18,5% das sonolentas. Com o carro em movimento, o RF calibrado e a regra disparam em 21,9% e 23,8% das janelas de motoristas acordados. Nos vídeos de microssono do NITYMED, o disparo do modelo do DMD (44,7%) fica no nível do disparo em motoristas acordados do DMD e não informa sensibilidade.

Nos vídeos, os óculos só puderam ser observados no DMD (3 motoristas), porque a UTA-RLDD não indica quais vídeos os têm. O detector falhou em um deles (F1 de piscadas de 0,108), em que o EAR cai apenas 14,2% ao fechar o olho, contra 30,4% a 55,6% sem óculos; com um caso em três, a falha não pode ser atribuída aos óculos.

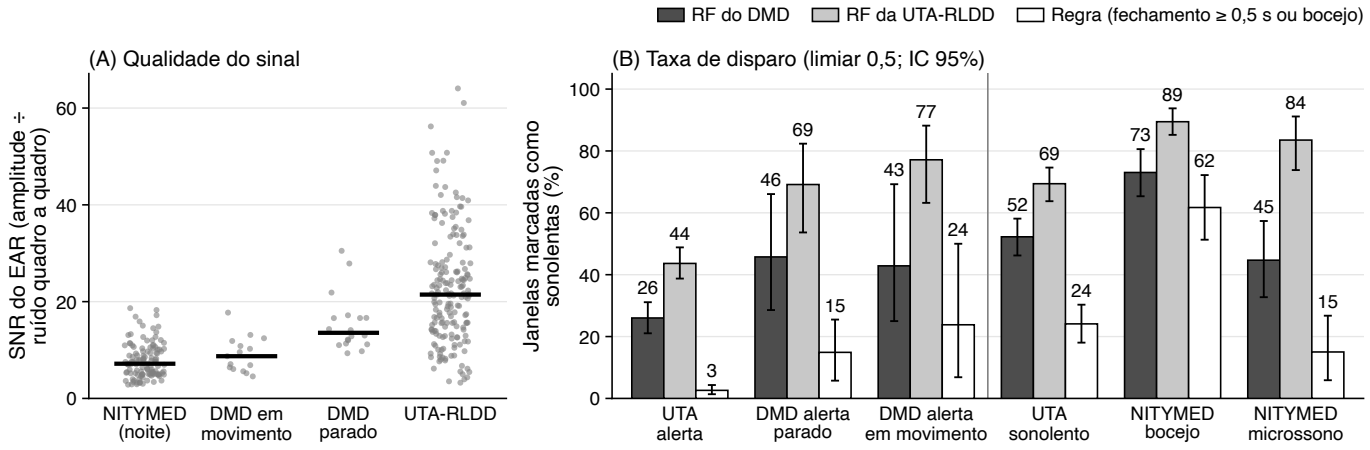


Figura 3. Exp. 6, com características brutas, pois o NITYMED não tem trecho alerta para a referência. (A) SNR do EAR por vídeo (traço = mediana); o DMD é de dia, com o carro em movimento ou parado. (B) Fração de janelas de 10 s marcadas como sonolentas no limiar 0,5 pelo RF do DMD, pelo RF da UTA-RLDD e pela regra de fechamento de 0,5 s ou mais ou bocejo, com IC 95%. No próprio domínio, os valores são fora da amostra (UTA-RLDD: 5 *folds*; DMD parado: um motorista de fora por vez); no DMD em movimento, os motoristas estão no treino com outras sessões.

E. Validação do protótipo

A Tabela V resume a versão 2.1. Contra a anotação do DMD, a combinação de EAR e *blendshape* marca o olho fechado com κ de 0,938 por quadro, contra 0,831 do EAR sozinho. O bocejo com a mão na boca quase nunca é detectado (1 de 38); no navegador, foram 6 de 24, todos entre os 14 sem a mão. Em 63,3 min de direção real com motoristas acordados (sessões s1 do DMD), todo o vermelho veio de um motorista (55,8% do tempo da sessão dele), cujo olhar para baixo o *blendshape* lê como olho fechado. Num teste independente, o mesmo motor rodou *offline*, sem a LSTM, nos vídeos alerta e sonolento das 24 pessoas dos *folds* oficiais 2 e 4 da UTA-RLDD, os únicos sem nenhuma das 3 pessoas acompanhadas no navegador durante o ajuste (escolha fixada antes de rodar; as outras 33 não foram testadas), com a calibração no início de cada vídeo, como no app. Houve alarme em 2 dos 24 vídeos acordados (0,46% do tempo em vermelho), e 15 dos 24 sonolentos chegaram ao vermelho. Na mesma base, com o alarme decidindo o vídeo e treino nos outros *folds* oficiais, Magán et al. [34] acertam 93% dos vídeos acordados e 35% dos sonolentos. Em 16 pessoas, o vídeo sonolento passou mais tempo fora do verde que o acordado; em 7, os dois ficaram verdes; e em 1, o contrário. Pelo tempo fora do verde, a AUC entre sonolento e acordado, agrupando os 48 vídeos, foi de 0,812 [0,705; 0,918] (0,855 com a calibração tirada do vídeo acordado). Nas mesmas pessoas, a AUC por vídeo do RF treinado no DMD, com centragem, foi de 0,811 e a da regra do rótulo, de 0,853; o RF treinado na própria UTA-RLDD chega a 0,953 com a centragem pelo vídeo alerta e fica em 0,806 sem ela. Com 24 pessoas, a única diferença detectável para o app é a do RF da UTA-RLDD com centragem, que fica acima dele (0,141 [0,042; 0,248] no *bootstrap* pareado). A queda da cabeça não tem revocação medida, pois o DMD não anota cabeceio. Para medir o peso das regras de projeto, sorteamos 300 configurações, com cada peso, teto e decaimento do nível entre 0,7 e 1,3 vez o valor escolhido e os limiares 40 e 70 deslocados em até 10 pontos. Entre os percentis 5 e 95, o tempo em vermelho foi de 1,7% a 4,9% na direção real e de 56,2% a 72,9% na sonolência atuada; pesam mais o limiar de 70 e o teto dos fechamentos. Os números do DMD são de desenvolvimento, pois as regras foram escolhidas nessas sessões.

Tabela V
VALIDAÇÃO DO PROTÓTIPO (PWA 2.1). MOTOR *offline* NO DMD, COM O FACE LANDMARKER E O CÓDIGO DO APP: S5 = SONOLÊNCIA ENCENADA COM ANOTAÇÃO; S1 = DIREÇÃO REAL COM MOTORISTAS ACORDADOS. NAVEGADOR: CHROME COM VÍDEOS REAIS NO LUGAR DA CÂMERA. UTA-RLDD: O MESMO MOTOR EM 24 PESSOAS FORA DO AJUSTE, UM VÍDEO ACORDADO E UM SONOLENTO DE CADA.

Medida	**Valor**
Olho fechado por quadro, κ (s5): *offline* / navegador (4 sessões)	0,938 / 0,902
Fechamentos de 1 s ou mais (s5): revocação / precisão	0,920 / 0,748
Bocejos (s5): revocação sem mão / com mão	0,638 / 0,026
Bocejos falsos em s1	0
Tempo em vermelho em s1 (%): versão 2.1 / lógica 1.0	3,3 / 55,6
Sessões de s1 sem alarme	16 de 17
Tempo em vermelho em s5 (%)	68,6
Pesos sorteados (300): vermelho em s1, percentis 5 e 95 (%)	1,7 a 4,9
UTA-RLDD, teste independente: acordados com alarme	2 de 24
UTA-RLDD, teste independente: sonolentos com vermelho	15 de 24
UTA-RLDD, teste independente: AUC sonolento × acordado	0,812 [0,705; 0,918]

VII. DISCUSSÃO

PP1. Treinar no DMD em vez da UTA-RLDD custa AUC com o mesmo extrator e as mesmas características, mas o tamanho da perda depende do modelo e da normalização: na RL, fica entre 5,4 e 9,8 pontos por janela em todas elas; no RF, os 10,9 pontos da configuração principal vêm em boa parte de B aproveitar a semelhança entre as janelas alertas e a referência tirada do mesmo vídeo; com outra referência na UTA-RLDD ou sem centragem, a diferença fica entre 2,1 e 2,3 pontos e não é detectável. Num app, a calibração e a sonolência acontecem na mesma sessão, e essa vantagem de B não se repetiria. O padrão de erro é estável: o modelo do DMD aprende com fechamentos longos e frequentes e deixa passar a sonolência real, em que eles são bem mais raros e o PERCLOS é baixo.

No mesmo cenário, o vazamento por janelas do mesmo vídeo infla a acurácia balanceada do RF em 12,6 pp, mais que a queda B−C (9,0 pp, que depende da referência); na RL, infla 1,2 pp, contra uma queda de 7,9 pp. Os 90,05% de [7], porém, foram medidos no conjunto de avaliação oficial do NTHU-DDD, com pessoas que não estavam no treino, e a distância até a UTA-RLDD não se explica por esse vazamento. Separar vídeos que não são a referência continua difícil: entre KSS 8 e 9 e KSS 6 e 7, a AUC fica em 61,5 mesmo com o RF treinado na UTA-RLDD.

PP2. O tempo mediano por quadro foi de 11 ms no iPhone 17 Pro e de 40 ms no Galaxy S23 Ultra, a maior parte no Face Landmarker, e a quantização int8 reduz a CNN a 72,1 KB com perda de no máximo 0,31 pp. A resposta vale para a PWA, em dois aparelhos de topo; não medimos bateria, aquecimento nem aparelhos de entrada.

PP3. A degradação não é uniforme: no estado ocular, a AUC entre bases cai com óculos, pouca luz e reflexo grande. À noite, a captura do rosto quase não muda, mas a SNR do EAR cai para 7,2; de dia, os mesmos motoristas do DMD vão de 13,6 a 8,7 com o carro em movimento. Parte da degradação atribuída à noite vem, portanto, do movimento, provavelmente pela vibração e pelos movimentos de cabeça, que não medimos (limitação 3). No limiar 0,5, os RF com características brutas disparam em muitas janelas de pessoas acordadas, e a regra sobre sinais visíveis em poucas, mas esse limiar é arbitrário. No mesmo falso alarme (limiar escolhido com os rótulos do teste, só como diagnóstico), a regra encontra tantas janelas sonolentas quanto a melhor variante do DMD, a RL com centragem (24,1% contra 24,7%), e mais que as outras três (de 15,3% a 19,2%), sem treino e com cada alarme explicável. Isso, somado à transferência limitada da PP1, justifica o desenho do protótipo: regras interpretáveis calibradas por usuário, com o modelo aprendido como reforço limitado. Nem o RF calibrado nem a regra do rótulo resolvem o carro em movimento (Seção VI-D); o app, que acumula eventos no tempo, ficou 3,3% do tempo em vermelho nessas sessões, num dado de desenvolvimento.

Limitações. (1) Os rótulos têm naturezas diferentes: eventos encenados e anotados no DMD e KSS relatado para o vídeo inteiro na UTA-RLDD, com cada estado gravado em outro momento; o Exp. 5b mede também uma troca de pergunta. (2) O DMD tem 13 motoristas atuados (87 janelas alertas), o carro parado nas sessões de treino e, na maioria dos sujeitos, o alerta gravado em outro dia; o tipo de sonolência continua misturado com a câmera e o cenário. (3) O NITYMED não tem classe alerta nem identificação do motorista, o que deixa otimistas os IC por vídeo, e a noite vem junto com outra câmera, outra compressão e outras pessoas. (4) O mapeamento entre sujeitos oficiais e pastas da UTA-RLDD, usado no Exp. 5a, é uma reconstrução nossa. (5) Os dois aparelhos foram medidos em execuções curtas, e o aplicativo Android nativo do repositório não foi avaliado. (6) As regras do protótipo foram escolhidas no DMD, mas o desenho geral foi guiado pelos Exp. 5b e 6, que usaram todas as pessoas da UTA-RLDD; o teste em sono real tem 24 pessoas sentadas, sem dirigir, com o sono declarado como rótulo; os pesos do nível não foram ajustados em sonolência real, e há um falso alarme conhecido em direção real. (7) As análises de sensibilidade são descritivas, sem correção para comparações múltiplas, e o desenho não foi pré-registrado.

Ética, LGPD e falsa segurança. O protótipo processa o vídeo no próprio aparelho, o que evita enviar dados biométricos, tratados como sensíveis pela Lei Geral de Proteção de Dados (LGPD); as bases foram usadas segundo seus termos e nenhum rosto foi publicado. Com internet, a biblioteca do MediaPipe envia ao Google estatísticas de uso, sem imagens nem pontos do rosto. O sistema detecta sinais visíveis, não o estado interno: quem relata sono sem sinais que o app detecte não é alertado, como 7 dos 24 sonolentos da UTA-RLDD, que ficaram no verde. Ele não é um dispositivo certificado, não diagnostica distúrbios do sono e não substitui o descanso previsto na Lei nº 13.103/2015; a ausência de alarme não significa condutor alerta.

VIII. Conclusão e Trabalhos Futuros

Com o mesmo extrator, RF e RL sobre 11 características e um único par de bases, modelos treinados com sonolência atuada (DMD) reconhecem a sonolência real (UTA-RLDD) pior que modelos treinados nela. Por janela, a regressão logística perde de 5,4 a 9,8 pontos de AUC em todas as normalizações testadas; o Random Forest perde 10,9 na principal, mas a diferença não é detectável com outra referência na UTA-RLDD. Os erros são compatíveis com uma sonolência atuada mais intensa que a real, mas parte da diferença vem da regra de rótulo do DMD e de diferenças entre as bases que este desenho não separa. O vazamento por trechos do mesmo vídeo infla a acurácia em até 45,3 pp nas sequências de piscadas e em 12,6 pp nas janelas do Exp. 5b, no RF. À noite, a perda de sinal ocular é compatível com a do carro em movimento. O protótipo segue essas evidências, com regras explicáveis sobre olhos, bocejo e cabeça, e a versão 2.1 teve tempo mediano por quadro de 11 ms num iPhone 17 Pro e de 40 ms num Galaxy S23 Ultra. Em 24 pessoas com sono real e fora do ajuste, ele separou os vídeos sonolentos dos acordados com AUC de 0,812, sem diferença detectável para o RF treinado no DMD e abaixo do RF treinado na UTA-RLDD com centragem; 7 dos 24 sonolentos ficaram no verde, a maioria sem fechamento longo, bocejo ou queda da cabeça detectados.

Como trabalhos futuros, propomos repetir a transferência com outra base de sonolência real, como o DROZY, e com a referência gravada na mesma sessão, como num app; validar o app em campo, com voluntários, KSS, óculos e noite; e medir a revocação da queda da cabeça.

Agradecimentos

Trabalho da disciplina Experiência Criativa: Projeto Transformador II (turma 8ºA, equipe 14), orientado pelo Prof. Júlio César Nievola. Agradecemos aos autores da UTA-RLDD, do DMD e do NITYMED por disponibilizarem as bases. Ferramentas de IA generativa foram usadas como apoio na

escrita do texto e do código; os autores conferiram todo o conteúdo e respondem por ele.

Referências

[1] P. Laboissière, "Transtornos de saúde causaram 28% dos sinistros em rodovias do país," Agência Brasil. https://agenciabrasil.ebc.com.br/saude/noticia/2026-05/transtornos-de-saude-causaram-28-dos-sinistros-em-rodovias-do-pais, maio 2026, acesso em 20/09/2026.

[2] Polícia Rodoviária Federal, "PRF divulga anuário estatístico de 2025, com aumento de infrações e redução de mortes nas rodovias federais," https://www.gov.br/prf/pt-br/noticias/nacionais/2026/maio/prf-divulga-anuario-estatistico-de-2025-com-aumento-de-infracoes-e-reducao-de-mortes-nas-rodovias-federais, maio 2026, Brasília. Acesso em 20/09/2026.

[3] R. Ghoddoosian, M. Galib, and V. Athitsos, "A realistic dataset and baseline temporal model for early drowsiness detection," in *Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2019, pp. 178–187, dataset: https://sites.google.com/view/utarldd/home.

[4] E. Perkins, C. Sitaula, M. Burke, and F. Marzbanrad, "Challenges of driver drowsiness prediction: The remaining steps to implementation," *IEEE Transactions on Intelligent Vehicles*, vol. 8, no. 2, pp. 1319–1338, 2023, versão preprint: arXiv:2109.08355.

[5] C.-H. Weng, Y.-H. Lai, and S.-H. Lai, "Driver drowsiness detection via a hierarchical temporal deep belief network," in *Computer Vision: ACCV 2016 Workshops, Revised Selected Papers, Part III*, ser. Lecture Notes in Computer Science, vol. 10118. Springer, 2017, pp. 117–133.

[6] S. Park, F. Pan, S. Kang, and C. D. Yoo, "Driver drowsiness detection system based on feature representation learning using various deep networks," in *Computer Vision: ACCV 2016 Workshops, Revised Selected Papers, Part III*, ser. Lecture Notes in Computer Science, vol. 10118. Springer, 2017, pp. 154–164.

[7] J. Lyu, Z. Yuan, and D. Chen, "Long-term multi-granularity deep framework for driver drowsiness detection," arXiv:1801.02325, 2018.

[8] Q. Shen, S. Zhao, R. Zhang, and B. Zhang, "Robust two-stream multi-features network for driver drowsiness detection," in *Proc. 2nd Int. Conf. on Robotics, Intelligent Control and Artificial Intelligence (RICAI 2020)*. Shanghai, China: ACM, 2020, pp. 271–277.

[9] R. Tamanani, R. Muresan, and A. Al-Dweik, "Estimation of driver vigilance status using real-time facial expression and deep learning," *IEEE Sensors Letters*, vol. 5, no. 5, pp. 1–4, 2021.

[10] W. W. Wierwille, S. S. Wreggit, C. L. Kirn, L. A. Ellsworth, and R. J. Fairbanks, "Research on vehicle-based driver status/performance monitoring: Development, validation, and refinement of algorithms for detection of driver drowsiness. Final Report," National Highway Traffic Safety Administration (NHTSA), Washington, DC, Tech. Rep. DOT HS 808 247, dez. 1994.

[11] D. F. Dinges and R. Grace, "PERCLOS: A valid psychophysiological measure of alertness as assessed by psychomotor vigilance," Federal Highway Administration, Office of Motor Carriers, Tech. Rep. FHWA-MCRT-98-006, out. 1998, Tech Brief.

[12] T. Soukupová and J. Čech, "Real-time eye blink detection using facial landmarks," in *Proc. 21st Computer Vision Winter Workshop (CVWW)*, Rimske Toplice, Slovenia, fev. 2016, https://cmp.felk.cvut.cz/ftp/articles/cech/Soukupova-CVWW-2016.pdf.

[13] J. D. Ortega, N. Kose, P. Cañas, M.-A. Chao, A. Unnervik, M. Nieto, O. Otaegui, and L. Salgado, "DMD: A large-scale multi-modal driver monitoring dataset for attention and alertness analysis," in *Computer Vision: ECCV 2020 Workshops*, ser. Lecture Notes in Computer Science, vol. 12538. Cham: Springer, 2020, pp. 387–405, https://dmd.vicomtech.org/.

[14] B. Bakker, B. Zabłocki, A. Baker, V. Riethmeister, B. Marx, G. Iyer, A. Anund, and C. Ahlström, "A multi-stage, multi-feature machine learning approach to detect driver sleepiness in naturalistic road driving conditions," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 5, pp. 4791–4800, 2022.

[15] Q. Massoz, J. G. Verly, and M. Van Droogenbroeck, "Multi-timescale drowsiness characterization based on a video of a driver's face," *Sensors*, vol. 18, no. 9, 2018, art. no. 2801.

[16] J. S. Wijnands, J. Thompson, K. A. Nice, G. D. P. A. Aschwanden, and M. Stevenson, "Real-time monitoring of driver drowsiness on mobile platforms using 3D neural networks," *Neural Computing and Applications*, vol. 32, no. 13, pp. 9731–9743, 2020.

[17] W. Xie and P. Xiao, "Confidence-driven adaptive time window for real-time driver fatigue detection in Level 2-3 autonomous vehicles: a multi-dataset validation study," *Frontiers in Neurorobotics*, vol. 20, 2026, art. no. 1857548.

[18] A. Pradeep and W. AlSaafin, "Baseline vs exploratory deep learning video models for driver drowsiness detection: A multi-dataset evaluation," in *Proc. 6th Int. Conf. on Electrical, Computer and Energy Technologies (ICECET)*. IEEE, 2026, pp. 1–5.

[19] M. M. Rahman, M. S. Islam, M. K. A. Jannat, M. H. Rahman, M. Arifuzzaman, R. Sassi, and M. Aktaruzzaman, "EyeNet: An improved eye states classification system using convolutional neural network," in *Proc. 22nd Int. Conf. on Advanced Communication Technology (ICACT)*, 2020, pp. 84–90.

[20] R. D. Florez-Zela, "Beyond aggregate scores: Deployment-aware and non-compensatory benchmarking of vision-based eye-state recognition models for driver monitoring," Preprint, arXiv:2606.08123v2, 2026.

[21] R. Jabbar, K. Al-Khalifa, M. Kharbeche, W. Alhajyaseen, M. Jafari, and S. Jiang, "Real-time driver drowsiness detection for Android application using deep neural networks techniques," *Procedia Computer Science*, vol. 130, pp. 400–407, 2018.

[22] A. Dasgupta, D. Rahman, and A. Routray, "A smartphone-based drowsiness detection and warning system for automotive drivers," *IEEE Transactions on Intelligent Transportation Systems*, vol. 20, no. 11, pp. 4045–4054, 2019.

[23] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, W.-T. Chang, W. Hua, M. Georg, and M. Grundmann, "MediaPipe: A framework for building perception pipelines," arXiv:1906.08172, 2019.

[24] Y. Kartynnik, A. Ablavatski, I. Grishchenko, and M. Grundmann, "Real-time facial surface geometry from monocular video on mobile GPUs," arXiv:1907.06724, 2019, CVPR Workshop on Computer Vision for Augmented and Virtual Reality.

[25] R. Krishnamoorthi, "Quantizing deep convolutional networks for efficient inference: A whitepaper," arXiv:1806.08342, 2018.

[26] N. Petrellis, N. Voros, C. Antonopoulos, G. Keramidas, P. Christakos, and P. Mousouliotis, "NITYMED: Night time yawning-microsleep-eyeblink-driver distraction dataset," IEEE DataPort, doi:10.21227/85xe-3f88, 2022.

[27] N. Petrellis, S. Zogas, P. Christakos, G. Keramidas, P. Mousouliotis, N. Voros, and C. Antonopoulos, "High speed implementation of the deformable shape tracking face alignment algorithm," in *Proc. 24th Euromicro Conf. on Digital System Design (DSD)*. Palermo, Italy: IEEE, set. 2021, pp. 174–177.

[28] R. Fusek, "Pupil localization using geodesic distance," in *Advances in Visual Computing: 13th Int. Symp. on Visual Computing (ISVC 2018)*, ser. Lecture Notes in Computer Science, vol. 11241. Cham: Springer, 2018, pp. 433–444, http://mrl.cs.vsb.cz/eyedataset.

[29] F. Song, X. Tan, X. Liu, and S. Chen, "Eyes closeness detection from still images with multi-scale histograms of principal oriented gradients," *Pattern Recognition*, vol. 47, no. 9, pp. 2825–2838, 2014.

[30] T. Åkerstedt and M. Gillberg, "Subjective and objective sleepiness in the active individual," *International Journal of Neuroscience*, vol. 52, no. 1-2, pp. 29–37, 1990.

[31] Comissão Europeia, "Regulamento delegado (UE) 2021/1341, de 23 de abril de 2021: sistemas de aviso de sonolência e atenção do condutor," Jornal Oficial da União Europeia, L 292, 16/08/2021. https://eur-lex.europa.eu/eli/reg_del/2021/1341/oj, 2021.

[32] J. Skorucak, A. Hertig-Godeschalk, P. Achermann, J. Mathis, and D. R. Schreier, "Automatically detected microsleep episodes in the fitness-to-drive assessment," *Frontiers in Neuroscience*, vol. 14, 2020, art. no. 8.

[33] Euro NCAP, "Safe driving: Driver engagement protocol, versão 1.2," https://cdn.euroncap.com/cars/assets/Euro_NCAP_Protocol_Safe_Driving_Driver_Engagement_v1_2_ebce03a443.pdf, jul. 2026, acesso em 07/11/2026.

[34] E. Magán, M. P. Sesmero, J. M. Alonso-Weber, and A. Sanchis, "Driver drowsiness detection by applying deep learning techniques to sequences of images," *Applied Sciences*, vol. 12, no. 3, p. 1145, 2022.