Detecção de Sonolência em Dispositivos Móveis: Avaliação da Generalização entre Sonolência Atuada e Real

André Luís Oliveira Ferreira da Silva, Bruno Rodolfo da Silveira,
Bruno Sandoval Ribeiro e Paulo Henrique Perin
Bacharelado em Ciência da Computação
Pontifícia Universidade Católica do Paraná (PUCPR), Curitiba, Brasil
{s.ferreira67, rodolfo.bruno, bruno.ribeiro, paulo.perin}@pucpr.edu.br

***Resumo*—Detectores de sonolência por vídeo passam de 90% de acurácia em bases *atuadas*, encenadas por voluntários, mas na UTA-RLDD, base de sonolência *real*, o modelo de base fica entre 54% e 65% em três classes. Medimos quanto do aprendido com sonolência atuada vale para a real, com o mesmo extrator nas duas bases, partição por sujeito e execução no celular. Treinados no DMD, os modelos ficam, por janela de 10 s, abaixo dos treinados na própria UTA-RLDD: a regressão logística perde de 5,4 a 9,8 pontos de AUC (área sob a curva ROC) em todas as normalizações testadas, e o Random Forest perde 10,9 na normalização principal, mas a diferença some com outro trecho de referência. O modelo do DMD reconhece só 48,4% das janelas sonolentas reais, de fechamentos de olho bem mais curtos que os encenados. Misturar trechos do mesmo vídeo no treino e no teste infla a acurácia do Random Forest em até 45,3 pontos percentuais em sequências de piscadas sobrepostas e 12,6 em janelas de 10 s. À noite o sinal do olho piora, mas o carro em movimento já o reduz a um nível que não se distingue do noturno. O protótipo, uma aplicação web para celular com regras explicáveis sobre olhos, bocejo e cabeça, separou os vídeos sonolentos dos acordados de 24 pessoas sentadas, fora do ajuste das regras, com AUC de 0,812 e processou cada quadro em 17 ms num iPhone 17 Pro (versão 1.0) e em 40 ms num Galaxy S23 Ultra (versão 2.1).**

***Palavras-chave*—detecção de sonolência, sonolência atuada, sonolência real, generalização entre bases, vazamento entre treino e teste, UTA-RLDD, DMD, smartphone**

I. Introdução

A sonolência ao volante é um problema de saúde pública no Brasil. Um levantamento da Associação Brasileira de Medicina de Tráfego (ABRAMET) sobre registros da Polícia Rodoviária Federal (PRF) associa 27,8% dos 4,34 milhões de ocorrências em rodovias federais de 2014 a 2024 a condições de saúde do condutor, categoria que inclui o sono, mas também falta de atenção, mal súbito e uso de substâncias [1]. No anuário da PRF de 2025, a "reação tardia ou ineficiente do condutor", causa compatível com a sonolência, aparece em 10.799 sinistros [2].

Há também uma lacuna de método. A maior parte dos detectores por vídeo é treinada e avaliada com sonolência *atuada*, em que voluntários encenam os sinais, e só 15 dos 126 estudos revisados por Perkins et al. [3] usam dados de estrada. Na base atuada mais usada, o NTHU-DDD [4], as acurácias publicadas vão de 73% [5] a valores entre 90% e 94% [6], [7]. Na UTA-RLDD (*UTA Real-Life Drowsiness Dataset*), base de sonolência *real*, o modelo de base acerta 54% das sequências de piscadas e 65,2% dos vídeos, e pessoas que assistiram aos vídeos acertaram 57,8% [8]. Os autores da UTA-RLDD deixam em aberto se vídeos de sonolência atuada servem de treino para detectar a real [8]. A diferença mistura três fatores: o tipo de sonolência; o protocolo, já que trechos da mesma pessoa ou do mesmo vídeo nos dois lados inflam a acurácia [3]; e a tarefa, que na UTA-RLDD tem três classes, uma delas intermediária. Há ainda a distância entre o computador em que os modelos são avaliados e o celular em que seriam úteis.

A pergunta central é: *quanto do desempenho obtido com sonolência atuada se mantém em sonolência real, com partição por sujeito e execução no celular?* Dela saem três perguntas de pesquisa. **PP1**: quanto se perde ao treinar com sonolência atuada e testar com sonolência real, em relação a treinar na própria base real, e quanto o vazamento entre treino e teste infla os números? **PP2**: qual o custo de executar o *pipeline* num celular, em tamanho, perda por quantização e tempo por quadro? **PP3**: a degradação é uniforme ou se concentra em condições de captura, como óculos, pouca luz, reflexos, noite e carro em movimento?

As contribuições são:

1) a medida da transferência da sonolência atuada do DMD (*Driver Monitoring Dataset*) para a real da UTA-RLDD com o mesmo extrator nas duas bases, um modelo de comparação treinado na base real, intervalos de confiança (IC) por sujeito e controles que mostram quando a queda depende da normalização por sujeito;
2) a medida do vazamento entre treino e teste com dados e modelos fixos, a reprodução do protocolo oficial da UTA-RLDD e a validação do nosso extrator contra as características oficiais;
3) a comparação do sinal do olho com o carro parado e em movimento, no mesmo motorista e com a mesma câmera, contrastada com vídeos noturnos, além da análise do estado ocular por óculos, iluminação e reflexos;
4) um protótipo de celular baseado em sinais interpretáveis (olhos, bocejo e cabeça), avaliado contra a anotação do

DMD, testado em sono real em 24 pessoas que não foram usadas para ajustar as regras e com o tempo por quadro medido em dois celulares. Código, *logs* e resultados estão no repositório do projeto[1].

II. Trabalhos Relacionados

Sinais visuais. O PERCLOS, fração do tempo com os olhos pelo menos 80% fechados, vem de um estudo em simulador feito para a agência de segurança viária dos Estados Unidos (NHTSA) [9] e mede fechamentos lentos, não piscadas [10]. Soukupová e Čech [11] definiram o *Eye Aspect Ratio* (EAR) com seis pontos por olho. Ghoddoosian et al. [8] criaram a UTA-RLDD, descreveram cada piscada por quatro características e as modelaram com uma rede recorrente LSTM (*long short-term memory*) hierárquica e multiescala (HM-LSTM). Entre as bases atuadas estão o NTHU-DDD [4] e o DMD [12].

Protocolos e generalização. Perkins et al. [3] apontam que muitos estudos põem trechos da mesma pessoa no treino e no teste e que os estudos comportamentais costumam pedir aos voluntários que encenem a sonolência. Bakker et al. [13], em direção real, obtêm 92% com um módulo personalizado por motorista e 72% sem ele, e Massoz et al. [14] mostram que o resultado depende da janela (70,68% com 5 s e 94,22% com 60 s). No NTHU-DDD, Wijnands et al. [15] relatam 73,9% com sujeitos separados. Entre bases de vídeo, Xie e Xiao [16] cruzam NTHU-DDD, YawDD, UTA-RLDD e DROZY e relatam queda média de 12,8 pontos percentuais (pp), e Pradeep e AlSaafin [17] medem a perda da UTA-RLDD para o DROZY. No estado ocular, os resultados de Rahman et al. [18] caem de cerca de 99% na mesma base para 90,94% do MRL para o CEW e 67,34% do CEW para o ZJU, e Florez-Zela [19], num *preprint*, relata queda do Macro-F1 de valores entre 0,96 e 0,98 no MRL para valores entre 0,21 e 0,78 no RT-BENE, sem retreino. Xie e Xiao [16] já cruzam bases atuadas e reais; até onde sabemos, nenhum trabalho compara, com o mesmo extrator, um modelo treinado em sonolência atuada com outro treinado na própria base real, nos mesmos sujeitos de teste e com controles da normalização por pessoa.

Celulares. Wijnands et al. [15] executam uma rede 3D num Galaxy S7 em 1,1 s por inferência de 10 quadros, Jabbar et al. [20] comprimem um classificador sobre pontos faciais em até 100 KB e Dasgupta et al. [21] combinam PERCLOS, voz e toque. O MediaPipe [22], [23] entrega a malha facial em tempo real no celular, e a quantização pós-treino em 8 bits costuma ficar a menos de 2 pp da versão em ponto flutuante [24].

III. Bases de Dados

A Tabela I resume as bases e o papel de cada uma.

Por que o DMD. Não usamos o NTHU-DDD porque o termo de licença exige a assinatura de uma chefia institucional. Usamos o DMD, que é RGB como a UTA-RLDD; em contrapartida, apenas 13 motoristas encenam sonolência (3 de óculos) e não há óculos escuros.

DMD. Na sessão de sonolência (s5), o carro está parado e os comportamentos são encenados; a anotação traz o estado do olho, as piscadas e os bocejos. A classe alerta vem dos trechos de direção segura da sessão s2 dos mesmos motoristas, também com o carro parado; a s1 é de direção com o carro em movimento, e a s3 serve de referência da normalização. Os trechos de direção segura duram de 10 a 26 s, o que definiu a janela de 10 s.

[1]https://github.com/BrunoRodolfoo/deteccao-sonolencia

Tabela I
Bases de dados e papel de cada uma (horas medidas nos arquivos processados).

Base	O que usamos	Papel
UTA-RLDD [8]	sonolência real; 60 sujeitos, 180 vídeos (31,55 h); rótulo KSS do vídeo	teste real (Exp. 1, 2, 5a, 5b e 6)
DMD [12]	sonolência atuada e direção; 14 motoristas, 65 sessões (4,24 h); eventos anotados por quadro	treino atuado (Exp. 5b); movimento (Exp. 6)
NITYMED [25], [26], [27]	noite, carro em movimento; 126 vídeos (1,63 h), sem classe alerta	condição noite (Exp. 6)
MRL Eye [28]	84.898 imagens de olho de 37 sujeitos, em infravermelho	estado do olho (Exp. 3)
CEW [29]	4.846 recortes de olho de fotos comuns	estado do olho (Exp. 3)

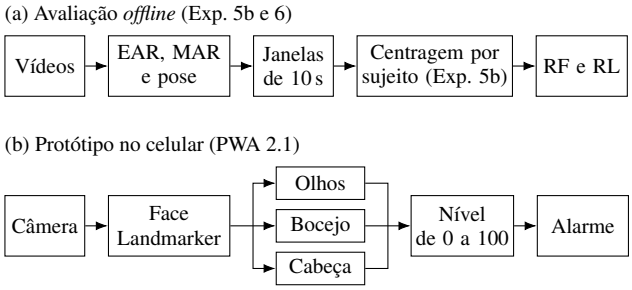


Figura 1. Cadeias de processamento. (a) Avaliação *offline* dos Exp. 5b e 6, com o mesmo extrator (Face Mesh do MediaPipe) e as mesmas características nas três bases; a centragem por sujeito vale apenas para o Exp. 5b, e o Exp. 6 usa as características brutas. (b) Protótipo no celular (aplicação web, versão 2.1): olhos, bocejo e cabeça somam pontos num nível de 0 a 100, que dispara o alarme a partir de 70.

NITYMED e UTA-RLDD. A página do NITYMED não diz se bocejos e microssonos foram espontâneos, e três bocejos por vídeo sugerem instrução; por isso essa base serve apenas à condição noite, nunca como evidência de sonolência real. Na UTA-RLDD, os rótulos vêm da escala de sonolência de Karolinska (KSS) [30], de 1 a 9: alerta (1 a 3), pouca vigilância (6 e 7) e sonolento (8 e 9), codificados como 0, 5 e 10. Os arquivos oficiais de características cobrem 58 dos 60 sujeitos. Nenhum quadro com rosto aparece neste artigo, por causa das licenças (DMD: CC BY-NC-ND 4.0; NITYMED: CC BY-ND 4.0) e da autorização parcial de imagem da UTA-RLDD.

IV. Método

A Fig. 1 resume as duas cadeias do trabalho.

A. Sinais, piscadas e características

Usamos o Face Mesh do MediaPipe [22], [23], na versão 0.10.21, que fornece 468 pontos do rosto por quadro. Deles

calculamos o EAR [11], que soma as duas alturas do olho e divide o total pelo dobro da largura, com a média dos dois olhos; a abertura da boca dividida pela largura (MAR); e a pose da cabeça. O olho conta como fechado quando o EAR fica abaixo de 0,75 vezes a mediana do EAR na referência do sujeito (Seção IV-B), e daí saem as piscadas e os fechamentos de 0,5 s ou mais. Contra a anotação quadro a quadro das 16 sessões s5 do DMD, esse detector tem F1 de piscadas de 0,749 e, por quadro, κ de Cohen de 0,773 (médias por sessão); o fator 0,75 foi fixado antes dessa validação.

Nos Exp. 1, 2 e 5a, cada piscada é descrita pelas quatro características de [8]: duração, amplitude, velocidade de abertura e frequência acumulada. Normalizadas por *z-score* do sujeito, elas formam sequências de 30 piscadas com passo 2, de modo que sequências vizinhas dividem 28 piscadas. Nos Exp. 5b e 6, a unidade é a janela de 10 s com passo de 5 s, descrita por 11 características que não dependem da taxa de quadros: PERCLOS, taxa de piscadas, duração média da piscada, maior fechamento, número de fechamentos de 0,5 s ou mais, média e desvio do EAR, amplitude e velocidade médias das piscadas, fração do tempo em bocejo (MAR acima de 0,5 por 1 s ou mais) e fração de quadros com rosto. A nota de um vídeo é a média das notas das suas janelas.

B. Rótulos, normalização e modelos

No DMD, uma janela é sonolenta se pertence à s5 e contém um fechamento anotado de 0,5 s ou mais ou um bocejo, e é alerta se está inteira num trecho de direção segura da s2. As janelas da s5 sem evento anotado ficam de fora, porque são ambíguas. Na UTA-RLDD, o rótulo é o do vídeo, e o esquema principal, B3, compara alerta (KSS de 1 a 3) com sonolento (KSS 8 e 9), como no DMD. Cada característica é centrada por sujeito: subtraímos a média de uma referência separada, que nunca entra na avaliação. Ela é a direção segura da s3 no DMD e o último terço do vídeo alerta na UTA-RLDD, como no código original. O *z-score* completo não é estimável em boa parte dos sujeitos do DMD, que têm poucas janelas de referência. Os classificadores são um Random Forest (RF) com 300 árvores e uma regressão logística (RL) com padronização, ambos com classes balanceadas, valores ausentes preenchidos pela mediana do treino e hiperparâmetros fixados antes. No Exp. 1, o RF usa 24 estatísticas de cada sequência, seis por característica, e uma LSTM de 32 unidades usa a sequência bruta. O estágio ocular usa uma rede neural convolucional (CNN) compacta própria, a EyeNet (diferente da homônima de [18]), com 62.865 parâmetros e recortes de 48×48 em tons de cinza, exportada em TFLite fp32 e int8.

C. Protótipo móvel

O protótipo é uma aplicação web progressiva (PWA, versão 2.1) que roda no navegador do celular, sem enviar vídeo. O Face Landmarker do MediaPipe fornece 478 pontos, 52 *blendshapes* e a pose da cabeça, e três sinais visíveis são calibrados em 10 s com a pessoa olhando para a frente:

- **olhos**: fechados quando os dois *eyeBlink* ficam altos ou quando o EAR cai abaixo de 0,75 do valor da calibração, com regras de exclusão para olhar para baixo, olhos apertados e olhar lateral. Fechamentos de 0,5 a 1 s somam pontos, e olhos fechados por 1 s ou mais (microssono, que dura de 1 a 15 s [31]) levam ao vermelho imediatamente. O PERCLOS de 60 s conta só fechamentos de 0,5 s ou mais;
- **bocejo**: *jawOpen* ou MAR acima do repouso por 1,5 s ou mais;
- **cabeça**: queda (cabeça 18° abaixo do repouso por 0,8 s) ou cabeceio, sempre *com os olhos fechados*. Cabeça baixa com os olhos abertos conta como distração e não soma pontos.

Os eventos somam pontos que decaem com o tempo num nível de 0 a 100. O estado passa a amarelo em 40 e a vermelho em 70, com histerese, e o vermelho toca uma sirene. Os pontos de um único sinal não chegam a 70; o microssono e a cabeça caída com os olhos fechados levam direto ao vermelho. A LSTM do Exp. 1 soma no máximo 10 pontos, e a CNN do Exp. 3 aparece na tela sem somar pontos. Os pesos do nível são regras de projeto, não ajustadas em sonolência real, porque não há base real com esses sinais marcados ao longo do tempo; a regra dos olhos e os ajustes finais foram escolhidos nos dados da validação, e a Seção VI-E mede quanto os pesos importam. A versão 1.0, substituída, alarmava por olho fechado, por um PERCLOS que contava piscadas ou pela LSTM sozinha.

V. Protocolo Experimental

A PP1 é respondida pelo Exp. 5b, com três cenários: A, DMD→DMD, deixando um sujeito de fora; B, UTA→UTA, nos 5 *folds* oficiais; e C, DMD→UTA. A queda da PP1 é B−C. Os Exp. 1 (reprodução do protocolo oficial), 2 (vazamento) e 5a (troca de extrator) apoiam a PP1; o Exp. 4 responde à PP2; e os Exp. 3 (estado ocular) e 6 (noite e movimento), à PP3. A numeração dos experimentos segue a do repositório do projeto. A área sob a curva ROC (AUC, $\times100$) mede a ordenação sem depender de limiar; a acurácia balanceada usa o limiar 0,5, fixado antes, e um limiar calibrado apenas no treino. Os intervalos de confiança de 95% (IC 95%) vêm de *bootstrap* percentil sobre sujeitos (1.000 reamostragens), pareado na queda B−C; numa análise adicional, os motoristas do DMD também são reamostrados, e C é treinado de novo a cada reamostragem. O Exp. 5a usa também permutação pareada por sujeito. No Exp. 6, a relação sinal-ruído (SNR) do EAR é a amplitude das piscadas dividida pelo ruído quadro a quadro, medido como o desvio robusto em torno de uma mediana móvel de 1 s; a taxa de disparo é a fração de janelas marcadas como sonolentas e, como o NITYMED não tem classe alerta, não é acurácia. A semente é 42 em todos os experimentos, e as partições aleatórias usam 42, 43 e 44. Cada número de resultado sai dos arquivos CSV do repositório por um *script* que registra arquivo, coluna e filtro, e um segundo *script* recalcula todos eles a partir desses arquivos.

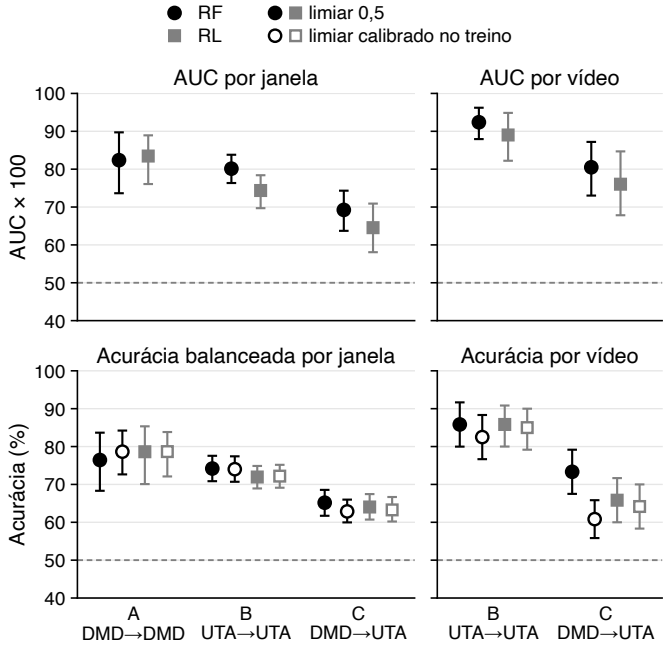


Figura 2. Exp. 5b: AUC e acurácia por janela e por vídeo nos cenários A (DMD→DMD), B (UTA→UTA) e C (DMD→UTA), com IC 95% por *bootstrap* de sujeitos; esquema B3 na UTA-RLDD (60 sujeitos, 5 *folds* oficiais) e 13 motoristas no DMD. Marcador cheio: limiar 0,5; vazado: limiar calibrado no treino. A linha tracejada marca o acaso; o DMD (A) não tem nível de vídeo.

VI. Resultados

A. PP1: da sonolência atuada para a real (Exp. 5b)

A Fig. 2 resume o experimento central. Na AUC por janela, o RF obtém 82,4 [73,6; 89,7] no DMD (A) e 80,1 [76,3; 83,8] na UTA-RLDD quando treinado nela (B). Treinado no DMD e aplicado à UTA-RLDD (C), fica em 69,2 [63,7; 74,3], acima do acaso. A queda B−C é de 10,9 [6,7; 15,7] pontos de AUC por janela e de 11,9 [5,6; 18,8] por vídeo (B: 92,4; C: 80,5). A RL repete o padrão, com queda de 9,8 [3,7; 16,0] por janela e de 13,0 [5,8; 20,8] por vídeo.

O modelo do DMD erra sobretudo ao chamar de alerta a sonolência real. No limiar 0,5, ele reconhece 82,0% das janelas alertas e só 48,4% das sonolentas, e o limiar calibrado no DMD (0,662) agrava o desequilíbrio (37,0% das sonolentas e 88,7% das alertas). As características brutas ajudam a entender o erro. Do alerta ao sonolento, a mediana do maior fechamento vai de 0,13 a 0,97 s no DMD e de 0,07 a 0,17 s na UTA-RLDD, e a do PERCLOS vai de 0,037 a 0,208 e de 0,010 a 0,040. A sonolência atuada aparece bem mais intensa que a real, em parte por construção, já que as janelas sonolentas do DMD são as que contêm um evento anotado e as da UTA-RLDD são todas as do vídeo sonolento.

A Tabela II mostra quanto da queda resiste aos controles. Na UTA-RLDD, as janelas alertas saem do mesmo vídeo usado como referência da normalização, e o RF treinado nela aproveita essa semelhança. Quando a referência vem do vídeo de pouca vigilância (KSS 6 e 7), que não entra na avaliação, ou quando não há centragem, a AUC de B no RF cai de 80,1 para 68,4 e 69,4, e a queda deixa de ser detectável; nessa

Tabela II
Exp. 5b: queda B−C da AUC (pontos), com IC 95%, sob controles da normalização e do treino; por janela, salvo onde indicado. Na configuração principal, a referência da UTA-RLDD é o último terço do vídeo alerta e a do DMD é a s3. Na última linha, mediana de 20 sorteios, sem IC.

Variação	RF	RL
Principal	10,9 [6,7; 15,7]	9,8 [3,7; 16,0]
IC com os motoristas do DMD reamostrados	[5,7; 19,5]	[1,9; 18,1]
UTA-RLDD: referência no vídeo de pouca vigilância	2,3 [−2,5; 6,8]	7,6 [3,0; 12,5]
O mesmo, por vídeo	−2,3 [−9,1; 4,3]	8,4 [3,4; 13,8]
DMD: referência na s2	9,0 [5,5; 13,2]	5,4 [0,3; 10,9]
Sem centragem	2,1 [−1,2; 5,8]	7,3 [3,0; 11,7]
Sem centragem, por vídeo	0,2 [−5,6; 6,3]	1,2 [−5,4; 7,9]
Contraste KSS 8 e 9 × 6 e 7	1,2 [−3,0; 5,8]	4,6 [−0,2; 9,7]
B treinado com 13 sujeitos	9,3	7,0

variante, o limiar de EAR do detector continua o do vídeo alerta. Entre dois vídeos que não são a referência, a queda não é detectável em nenhum dos dois modelos, e por vídeo, sem centragem, também não. Na RL, a queda por janela fica entre 5,4 e 9,8 pontos nas quatro normalizações testadas, sempre com IC acima de zero. O volume do treino explica pouco: com 13 sujeitos da UTA-RLDD por *fold*, como no DMD, a queda fica em 9,3 pontos no RF e 7,0 na RL. Reamostrar também os motoristas do DMD alarga o IC da queda principal, que fica acima de zero. Usar como alerta do DMD a direção com o carro em movimento (s1) piora a transferência (AUC de C de 69,2 para 58,6). As variações de janela (5 e 15 s), de alerta e de referência no DMD e a exclusão do motorista em que o detector falhou mantêm a referência no vídeo alerta da UTA-RLDD; nelas, o IC da queda fica acima de zero no RF e na RL, exceto na RL com janelas de 5 s (5,4 [−0,1; 10,8]).

B. Protocolo, reprodução e extrator (Exp. 1, 2 e 5a)

A Tabela III reúne os números de referência. No protocolo oficial, o RF sobre 24 estatísticas das piscadas empata com a HM-LSTM na acurácia por sequência (BSA, do inglês *blink sequence accuracy*) e fica 7,9 pp abaixo na acurácia por vídeo (VA), no nível do julgamento humano. Sem a classe intermediária (B3), chega à acurácia balanceada de 84,8% (acaso: 50%), com a mesma estrutura de referência discutida acima. Repartir as mesmas sequências ao acaso, com sequências do mesmo vídeo nos dois lados, infla a BSA em 45,3 pp no RF e 38,1 pp na LSTM; como sequências vizinhas dividem 28 das 30 piscadas, o teste vê quase as mesmas sequências do treino. A partição por vídeo, em que o treino tem os outros vídeos do mesmo sujeito com rótulos diferentes, fica *abaixo* da partição por sujeito (−7,0 pp); uma explicação provável, que não isolamos, é que o modelo associa o padrão de piscadas da pessoa a rótulos que não são os do vídeo de teste. Nesta base, o que infla a acurácia é o mesmo vídeo, e com ele o mesmo rótulo, aparecer nos dois lados. No cenário do Exp. 5b, com janelas de 10 s e duas classes, a partição aleatória de janelas infla a acurácia balanceada em 12,6 pp no RF e em 1,2 pp na RL: o vazamento pesa nos modelos flexíveis, capazes de memorizar janelas vizinhas.

Trocar o extrator dos autores (dlib) pelo nosso (MediaPipe), com o RF treinado nas características oficiais, custa 2,0 [−4,8;

Tabela III
EXP. 1 E 2, TRÊS CLASSES (%): 5 *folds* OFICIAIS (MÉDIA ± DP) E AS MESMAS SEQUÊNCIAS SOB TRÊS PARTIÇÕES. BSA: ACURÁCIA POR SEQUÊNCIA DE 30 PISCADAS; VA: POR VÍDEO; N/A: NÃO SE APLICA. VALORES DE [8] PARA A HM-LSTM E OS HUMANOS. A PARTIÇÃO POR SUJEITO DO EXP. 2 SORTEIA OS SUJEITOS E DIFERE DOS 5 *folds* OFICIAIS.

Modelo	**Partição**	**BSA**	**VA**
RF (24 estatísticas)	5 *folds* oficiais	$54{,}5 \pm 9{,}3$	$57{,}3 \pm 7{,}2$
LSTM (30×4)	5 *folds* oficiais	$50{,}8 \pm 8{,}9$	$57{,}2 \pm 7{,}5$
HM-LSTM [8]	5 *folds* oficiais	54,0	65,2
Humanos [8]	n/a	n/a	57,8
Classe majoritária	n/a	44,4	33,3
RF	aleatória	99,5	n/a
RF	por vídeo	47,2	52,8
RF	por sujeito	54,2	55,7
LSTM	aleatória	87,3	n/a
LSTM	por sujeito	49,2	50,8

Tabela IV
EXP. 4. (A) MODELOS E QUANTIZAÇÃO. (B) TEMPO POR QUADRO NA PWA, EM MS: MEDIANA, ENTRE AS EXECUÇÕES DE 60 S, DO P50 E DO P95 DE CADA EXECUÇÃO.

(a) Modelos

CNN do olho: fp32 → int8 (KB)	248,2 → 72,1
Maior perda de acurácia com int8 (pp)	0,31
LSTM: parâmetros / tamanho (KB)	5.324 / 101,8

(b) *Pipeline* completo, CNN int8 (p50 / p95)

Estágio	**iPhone 17 Pro** app 1.0	**Galaxy S23 Ultra** app 2.1
Face Landmarker	14,0 / 18,5	21,9 / 24,8
CNN, 2 olhos	2,5 / 4,5	16,1 / 28,9
LSTM	1,0 / 1,0	0,6 / 0,7
Motor de sinais	n/a / n/a	0,1 / 0,2
Total por quadro	17,0 / 22,0	39,5 / 53,1

8,5] pp de acurácia balanceada em três classes ($p = 0{,}555$; 47 sujeitos), diferença que não se distingue de zero. Com cada extrator no próprio treino e teste, o nosso não fica atrás (oficial menos nosso em B3: $-6{,}7$ [$-12{,}9$; $-1{,}8$] pp nos 5 *folds* e $-4{,}5$ [$-11{,}0$; 0,6] pp deixando um sujeito de fora). O IC largo não prova equivalência, mas não há perda detectável, e usamos o nosso extrator nas duas pontas do Exp. 5b.

C. PP2: custo no celular (Exp. 4)

A Tabela IV reúne as medidas. A CNN do olho cai de 248,2 para 72,1 KB em int8, com perda de no máximo 0,31 pp, e a LSTM exportada concorda com o modelo original em Keras em 100,0% das sequências. No iPhone 17 Pro (iOS 26.6.1, Chrome 154 (iOS, motor WebKit), Face Landmarker na GPU), 2 execuções de 60 s da versão 1.0 do app somaram 6.031 quadros, 100,0% deles com rosto, e o tempo total por quadro (p50) ficou entre 11,0 e 23,0 ms nas execuções, dominado pelo Face Landmarker. No Galaxy S23 Ultra (Android 16, Chrome 156), 3 execuções da versão 2.1 ficaram entre 39,1 e 40,1 ms por quadro. O iPhone registra os tempos em milissegundos inteiros, o que limita a precisão dos estágios mais rápidos. Numa execução da versão 1.0, com um dos autores acordado diante da câmera, a lógica antiga acusou PERCLOS de 25,8% e manteve o alarme ligado em 63,4% dos quadros; esse falso alarme motivou a reescrita descrita na Seção IV-C.

D. PP3: condições de captura (Exp. 3 e 6)

No estado ocular, a EyeNet atinge $94{,}1 \pm 3{,}4$% em sujeitos não vistos do MRL, $79{,}0 \pm 8{,}5$% do MRL para o CEW (média dos *folds*; 85,7% com o modelo treinado em todos os sujeitos) e $68{,}1 \pm 1{,}9$% do CEW para o MRL. Do CEW para o MRL, a AUC cai com óculos (65,1 contra 93,4 sem óculos), pouca luz (81,1 contra 89,6) e reflexo grande (69,2 contra 86,9). Essas condições estão ligadas entre si e aos sujeitos, e as diferenças devem ser lidas como associações.

À noite, o rosto continua sendo encontrado em 99,15% dos quadros do NITYMED, contra 99,77% na UTA-RLDD (diferença de $-0{,}61$ [$-1{,}07$; $-0{,}14$] pp). O que cai é a qualidade do sinal (Fig. 3A): a SNR do EAR é de 7,2 [6,4; 7,9] no NITYMED, contra 21,5 na UTA-RLDD e 13,6 no DMD parado. Mas os mesmos motoristas do DMD, de dia e com o carro em movimento, ficam em 8,7. No mesmo motorista e com a mesma câmera, o movimento muda a SNR em $-5{,}4$ [$-6{,}6$; $-3{,}5$] (11 motoristas), e a diferença entre a noite e o carro em movimento não se distingue de zero ($-1{,}6$ [$-3{,}7$; 1,1]). Com estes dados, a perda de sinal acompanha a condução real, e um efeito adicional da escuridão não é detectável. Sem um trecho alerta do próprio motorista, como o da calibração do protótipo, o PERCLOS também não separa microssono de ruído de condução: com o limiar tirado do próprio vídeo, sua mediana sobe tanto nos vídeos de microssono do NITYMED (19,5%) quanto nos motoristas acordados do DMD em movimento (18,4%).

Na Fig. 3B, sem centragem, que o NITYMED não permite por falta de trecho alerta, os dois RF marcam como sonolentas de 26,0% a 43,6% das janelas de pessoas acordadas da UTA-RLDD no limiar 0,5. A regra do rótulo do DMD aplicada aos nossos sinais (fechamento de 0,5 s ou mais, com o limiar de EAR do próprio sujeito, ou bocejo) marca 2,6% ([1,4; 4,3]). Com o limiar calibrado no treino, o RF do DMD dispara ainda menos (1,7%), mas encontra menos janelas sonolentas que a regra (11,0% contra 24,1%); a RL do DMD, no limiar 0,5, marca 2,3% das janelas alertas e 18,5% das sonolentas. Com o carro em movimento, o RF calibrado e a regra disparam em 21,9% e 23,8% das janelas de motoristas acordados. Nos vídeos de microssono do NITYMED, o disparo do modelo do DMD (44,7%) fica no nível do disparo em motoristas acordados do DMD e não informa sensibilidade.

Nos vídeos, os óculos só puderam ser observados no DMD (3 motoristas), porque a UTA-RLDD não indica quais vídeos os têm. O detector falhou em um deles (F1 de piscadas de 0,108), em que o EAR cai apenas 14,2% ao fechar o olho, contra 30,4% a 55,6% sem óculos; com um caso em três, a falha não pode ser atribuída aos óculos.

E. Validação do protótipo

A Tabela V resume a versão 2.1. Contra a anotação do DMD, a combinação de EAR e *blendshape* marca o olho fechado com κ de 0,938 por quadro, contra 0,831 do EAR sozinho. O bocejo com a mão na boca quase nunca é detectado (1 de 38); no navegador, foram 6 de 24, todos entre os 14 sem a mão. Em 63,3 min de direção real com motoristas acordados

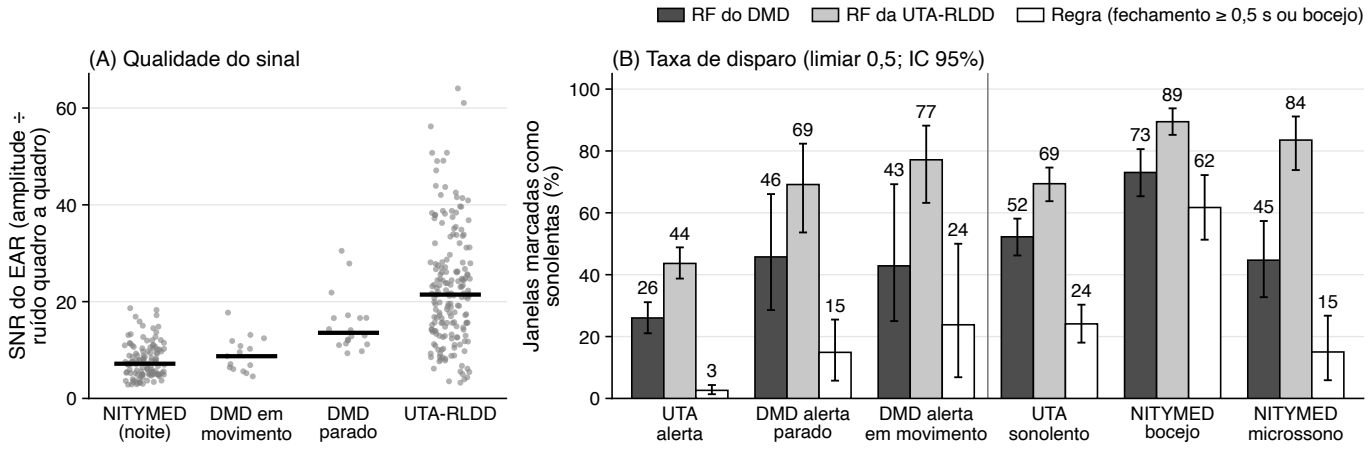


Figura 3. Exp. 6, com características brutas, pois o NITYMED não tem trecho alerta para a referência. (A) SNR do EAR por vídeo (traço = mediana); o DMD é de dia, com o carro em movimento ou parado. (B) Fração de janelas de 10 s marcadas como sonolentas no limiar 0,5 pelo RF do DMD, pelo RF da UTA-RLDD e pela regra de fechamento de 0,5 s ou mais ou bocejo, com IC 95%; a linha vertical separa os grupos de pessoas acordadas dos sonolentos e noturnos. No próprio domínio, os valores são fora da amostra (UTA-RLDD: 5 *folds*; DMD parado: um motorista de fora por vez); no DMD em movimento, os motoristas estão no treino com outras sessões. Nenhum valor no NITYMED é acurácia.

(sessões s1 do DMD), todo o vermelho veio de um motorista (55,8% do tempo da sessão dele), cujo olhar para baixo o *blendshape* lê como olho fechado. Num teste independente, o mesmo motor rodou em 24 pessoas da UTA-RLDD que não foram usadas para ajustar as regras (todas as dos *folds* oficiais 2 e 4), com os vídeos acordado e sonolento de cada uma e a calibração no início de cada vídeo, como no app. Houve alarme em 2 dos 24 vídeos acordados (0,46% do tempo em vermelho), e 15 dos 24 sonolentos chegaram ao vermelho. Em 16 pessoas, o vídeo sonolento passou mais tempo fora do verde que o acordado; em 7, os dois ficaram verdes; e em 1, o contrário. Pelo tempo fora do verde, a AUC entre sonolento e acordado foi de 0,812 [0,705; 0,918] (0,855 com a calibração tirada do vídeo acordado). Nas mesmas pessoas, a AUC por vídeo do RF treinado no DMD foi de 0,811 e a da regra do rótulo, de 0,853; o RF treinado na própria UTA-RLDD chega a 0,953 com a centragem pelo vídeo alerta e fica em 0,806 sem ela. O app, sem treino nessa base, fica no nível desses detectores. Essas pessoas estavam sentadas, sem dirigir, e o rótulo é o sono declarado. A queda da cabeça não tem revocação medida, pois o DMD não anota cabeceio; há apenas um teste sintético, com o vídeo girado, e casos isolados. Para medir o peso das regras de projeto, sorteamos 300 configurações, com cada peso, teto e decaimento do nível entre 0,7 e 1,3 vez o valor escolhido e os limiares 40 e 70 deslocados em até 10 pontos. O tempo em vermelho na direção real ficou entre 1,7% e 4,9% (percentis 5 e 95) e o da sonolência encenada entre 56,2% e 72,9%; os números que mais pesam são o limiar de 70 e o teto dos fechamentos. Os números do DMD são de desenvolvimento, porque a regra dos olhos e os ajustes da versão 2.1 foram escolhidos comparando variantes nessas mesmas sessões; o teste na UTA-RLDD não teve ajuste.

Tabela V
VALIDAÇÃO DO PROTÓTIPO (PWA 2.1). MOTOR *offline* NO DMD, COM O FACE LANDMARKER E O CÓDIGO DO APP: S5 = SONOLÊNCIA ENCENADA COM ANOTAÇÃO; S1 = DIREÇÃO REAL COM MOTORISTAS ACORDADOS. NAVEGADOR: CHROME COM VÍDEOS REAIS NO LUGAR DA CÂMERA. UTA-RLDD: O MESMO MOTOR EM 24 PESSOAS QUE NÃO FORAM USADAS PARA AJUSTAR AS REGRAS, UM VÍDEO ACORDADO E UM SONOLENTO DE CADA. VERDE, AMARELO E VERMELHO SÃO OS ESTADOS DO NÍVEL.

Medida	**Valor**
Olho fechado por quadro, κ (s5): *offline* / navegador (4 sessões)	0,938 / 0,902
Fechamentos de 1 s ou mais (s5): revocação / precisão	0,920 / 0,748
Bocejos (s5): revocação sem mão / com mão	0,638 / 0,026
Bocejos falsos em s1	0
Tempo em vermelho em s1 (%): versão 2.1 / lógica 1.0	3,3 / 55,6
Sessões de s1 sem alarme	16 de 17
Tempo em vermelho em s5 (%)	68,6
Pesos sorteados (300): vermelho em s1, percentis 5 e 95 (%)	1,7 a 4,9
UTA-RLDD, teste independente: acordados com alarme	2 de 24
UTA-RLDD, teste independente: sonolentos com vermelho	15 de 24
UTA-RLDD, teste independente: AUC sonolento × acordado	0,812 [0,705; 0,918]

VII. DISCUSSÃO

PP1. Treinar no DMD em vez da UTA-RLDD custa AUC com o mesmo extrator e as mesmas características, mas o tamanho da perda depende do modelo e da normalização. Na RL, ela fica entre 5,4 e 9,8 pontos por janela nas quatro normalizações testadas. No RF, os 10,9 pontos da configuração principal vêm em boa parte de B aproveitar a semelhança entre as janelas alertas e a referência tirada do mesmo vídeo; com outra referência na UTA-RLDD ou sem centragem, a diferença fica entre 2,1 e 2,3 pontos e não é detectável. Num app, a calibração e a sonolência acontecem na mesma sessão, e essa vantagem de B não se repetiria. O padrão de erro é estável: o modelo do DMD aprende com eventos longos e deixa passar a sonolência real, de fechamentos curtos e PERCLOS baixo. Com um único par de bases, a queda ainda se mistura com a câmera, o cenário e a natureza do rótulo, que no DMD é um evento encenado e na UTA-RLDD é o estado relatado.

No mesmo cenário, o vazamento por janelas do mesmo vídeo infla a acurácia balanceada do RF em 12,6 pp, mais que a queda B−C (9,0 pp, que depende da referência); na RL, infla 1,2 pp, contra uma queda de 7,9 pp. O protocolo pesa muito nos modelos capazes de memorizar janelas vizinhas e pouco no modelo linear. Os 90,05% de [6], porém, foram medidos

no conjunto de avaliação oficial do NTHU-DDD, com pessoas que não estavam no treino, e a distância até a UTA-RLDD não se explica por esse vazamento. Separar vídeos que não são a referência continua difícil: entre KSS 8 e 9 e KSS 6 e 7, a AUC fica em 61,5 mesmo com o RF treinado na UTA-RLDD.

PP2. O tempo por quadro foi de 17 ms no iPhone 17 Pro (de 11 a 23 ms nas execuções, versão 1.0) e de 40 ms no Galaxy S23 Ultra (versão 2.1), com a maior parte no rastreador facial; no Galaxy, a CNN dos olhos levou 16,1 ms. A CNN e a LSTM entram na medida porque rodam a cada quadro, embora pesem pouco no nível. Os modelos aprendidos ocupam 72,1 KB (CNN int8) e 101,8 KB (LSTM), e a quantização custa no máximo 0,31 pp. A resposta vale para a PWA no navegador, em dois aparelhos de topo e em execuções de 60 s; não medimos bateria, aquecimento em uso longo nem aparelhos de entrada.

PP3. A degradação não é uniforme: no estado ocular, a AUC entre bases cai com óculos, pouca luz e reflexo grande. À noite, a captura do rosto quase não muda, mas a SNR do EAR cai para 7,2; de dia, os mesmos motoristas do DMD vão de 13,6 a 8,7 com o carro em movimento. Parte da degradação atribuída à noite vem, portanto, do movimento, provavelmente pela vibração e pelos movimentos de cabeça, que não medimos, embora a comparação com o NITYMED não isole a escuridão (limitação 3). No limiar 0,5, os RF com características brutas disparam em muitas janelas de pessoas acordadas, e a regra sobre sinais visíveis em poucas, mas esse limiar é arbitrário. No mesmo falso alarme (limiar escolhido com os rótulos do teste, só como diagnóstico), a regra encontra tantas janelas sonolentas quanto a melhor variante do DMD, a RL com centragem (24,1% contra 24,7%), e mais que as outras três (de 15,3% a 19,2%), sem treino e com cada alarme explicável. Isso, somado à transferência limitada da PP1, justifica o desenho do protótipo: regras interpretáveis calibradas por usuário, com o modelo aprendido como reforço limitado. Em pessoas com sono real que não foram usadas para ajustar as regras, elas separaram o vídeo sonolento do acordado com AUC de 0,812, no nível dos modelos treinados. Nem o RF calibrado nem a regra do rótulo resolvem o carro em movimento: disparam em 21,9% e 23,8% das janelas de motoristas acordados, enquanto o app, que acumula eventos no tempo, ficou 3,3% do tempo em vermelho nessas sessões, num dado de desenvolvimento.

Limitações. (1) Os rótulos têm naturezas diferentes: eventos encenados e anotados no DMD e KSS relatado para o vídeo inteiro na UTA-RLDD, com cada estado gravado em outro momento; o Exp. 5b mede também uma troca de pergunta. (2) O DMD tem 13 motoristas atuados (87 janelas alertas), o carro parado nas sessões de treino e, na maioria dos sujeitos, o alerta gravado em outro dia; o tipo de sonolência continua misturado com a câmera e o cenário. (3) O NITYMED não tem classe alerta nem identificação do motorista, o que deixa otimistas os IC por vídeo, e a noite vem junto com outra câmera, outra compressão e outras pessoas. (4) O mapeamento entre sujeitos oficiais e pastas da UTA-RLDD, usado no Exp. 5a, é uma reconstrução nossa. (5) Os dois aparelhos foram medidos em execuções curtas, o iPhone ainda com a versão 1.0 do app, e o aplicativo Android nativo do repositório não foi avaliado. (6) As regras do protótipo foram escolhidas no DMD, mas o desenho geral foi guiado pelos Exp. 5b e 6, que usaram todas as pessoas da UTA-RLDD; o teste em sono real tem 24 pessoas sentadas, sem dirigir, com o sono declarado como rótulo; os pesos do nível não foram ajustados em sonolência real, há um falso alarme conhecido em direção real e a queda da cabeça não tem revocação medida. (7) As análises de sensibilidade são descritivas, sem correção para comparações múltiplas, e o desenho não foi pré-registrado.

Ética, LGPD e falsa segurança. O protótipo processa o vídeo no próprio aparelho, o que evita enviar dados biométricos, tratados como sensíveis pela Lei Geral de Proteção de Dados (LGPD); as bases foram usadas segundo seus termos e nenhum rosto foi publicado. O sistema detecta sinais visíveis, não o estado interno: quem relata sono sem sinais que o app detecte não é alertado, como 7 dos 24 sonolentos da UTA-RLDD, que ficaram no verde. Ele não é um dispositivo certificado, não diagnostica distúrbios do sono e não substitui o descanso previsto na Lei nº 13.103/2015; a ausência de alarme não significa condutor alerta.

VIII. Conclusão e Trabalhos Futuros

Com o mesmo extrator nas duas bases, modelos treinados com sonolência atuada (DMD) reconhecem a sonolência real (UTA-RLDD) pior que modelos treinados nela. Por janela, a regressão logística perde de 5,4 a 9,8 pontos de AUC em todas as normalizações testadas; o Random Forest perde 10,9 na principal, mas a diferença não é detectável com outra referência na UTA-RLDD. Os erros são compatíveis com uma sonolência atuada mais intensa que a real, mas parte da diferença vem da regra de rótulo do DMD e de diferenças entre as bases que este desenho não separa. O vazamento por trechos do mesmo vídeo infla a acurácia em até 45,3 pp nas sequências de piscadas e em 12,6 pp nas janelas do Exp. 5b, no RF. À noite, a perda de sinal ocular é compatível com a do carro em movimento. O protótipo segue essas evidências, com regras explicáveis sobre olhos, bocejo e cabeça, e processou cada quadro em 17 ms num iPhone 17 Pro (versão 1.0) e em 40 ms num Galaxy S23 Ultra (versão 2.1). Em 24 pessoas com sono real que não foram usadas para ajustar as regras, ele separou os vídeos sonolentos dos acordados com AUC de 0,812, no nível dos modelos treinados, mas 7 dos 24 sonolentos ficaram no verde, a maioria sem fechamento longo, bocejo ou queda da cabeça detectados.

Como trabalhos futuros, propomos repetir a transferência com outra base de sonolência real, como o DROZY, e com a referência gravada na mesma sessão, como num app; validar o app em campo, com voluntários, KSS, óculos e noite; e medir a revocação da queda da cabeça.

Agradecimentos

Trabalho da disciplina Experiência Criativa: Projeto Transformador II (turma 8ºA, equipe 14), orientado pelo Prof. Júlio César Nievola. Agradecemos aos autores da UTA-RLDD,

do DMD e do NITYMED por disponibilizarem as bases. Ferramentas de IA generativa foram usadas como apoio na escrita do texto e do código; os autores conferiram todo o conteúdo e respondem por ele.

REFERÊNCIAS

[1] P. Laboissière, "Transtornos de saúde causaram 28% dos sinistros em rodovias do país," Agência Brasil. https://agenciabrasil.ebc.com.br/saude/noticia/2026-05/transtornos-de-saude-causaram-28-dos-sinistros-em-rodovias-do-pais, maio 2026, publicado em 12/05/2026; levantamento da ABRAMET sobre dados da PRF de 2014 a 2024. Acesso em 20/09/2026.

[2] Polícia Rodoviária Federal, "PRF divulga anuário estatístico de 2025, com aumento de infrações e redução de mortes nas rodovias federais," https://www.gov.br/prf/pt-br/noticias/nacionais/2026/maio/prf-divulga-anuario-estatistico-de-2025-com-aumento-de-infracoes-e-reducao-de-mortes-nas-rodovias-federais, maio 2026, Brasília. Acesso em 20/09/2026.

[3] E. Perkins, C. Sitaula, M. Burke, and F. Marzbanrad, "Challenges of driver drowsiness prediction: The remaining steps to implementation," *IEEE Transactions on Intelligent Vehicles*, vol. 8, no. 2, pp. 1319–1338, 2023, arXiv:2109.08355.

[4] C.-H. Weng, Y.-H. Lai, and S.-H. Lai, "Driver drowsiness detection via a hierarchical temporal deep belief network," in *Computer Vision: ACCV 2016 Workshops, Revised Selected Papers, Part III*, ser. Lecture Notes in Computer Science, vol. 10118. Springer, 2017, pp. 117–133.

[5] S. Park, F. Pan, S. Kang, and C. D. Yoo, "Driver drowsiness detection system based on feature representation learning using various deep networks," in *Computer Vision: ACCV 2016 Workshops, Revised Selected Papers, Part III*, ser. Lecture Notes in Computer Science, vol. 10118. Springer, 2017, pp. 154–164.

[6] J. Lyu, Z. Yuan, and D. Chen, "Long-term multi-granularity deep framework for driver drowsiness detection," arXiv:1801.02325, 2018.

[7] Q. Shen, S. Zhao, R. Zhang, and B. Zhang, "Robust two-stream multi-features network for driver drowsiness detection," in *Proc. 2nd Int. Conf. on Robotics, Intelligent Control and Artificial Intelligence (RICAI 2020)*. Shanghai, China: ACM, 2020, pp. 271–277, preprint: arXiv:2010.06235.

[8] R. Ghoddoosian, M. Galib, and V. Athitsos, "A realistic dataset and baseline temporal model for early drowsiness detection," in *Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2019, pp. 178–187, arXiv:1904.07312. Dataset: https://sites.google.com/view/utarldd/home.

[9] W. W. Wierwille, S. S. Wreggit, C. L. Kirn, L. A. Ellsworth, and R. J. Fairbanks, "Research on vehicle-based driver status/performance monitoring: Development, validation, and refinement of algorithms for detection of driver drowsiness. Final Report," National Highway Traffic Safety Administration (NHTSA), Washington, DC, Tech. Rep. DOT HS 808 247, dez. 1994, 247 p. Também VPISU ISE 94-04. Registro TRID 00712943 (https://trid.trb.org/view/448128).

[10] D. F. Dinges and R. Grace, "PERCLOS: A valid psychophysiological measure of alertness as assessed by psychomotor vigilance," Federal Highway Administration, Office of Motor Carriers, Tech. Rep. FHWA-MCRT-98-006, out. 1998, Tech Brief.

[11] T. Soukupová and J. Čech, "Real-time eye blink detection using facial landmarks," in *Proc. 21st Computer Vision Winter Workshop (CVWW)*, L. Čehovin, R. Mandeljc, and V. Štruc, Eds., Rimske Toplice, Slovenia, fev. 2016, PDF oficial: https://cmp.felk.cvut.cz/ftp/articles/cech/Soukupova-CVWW-2016.pdf.

[12] J. D. Ortega, N. Kose, P. Cañas, M.-A. Chao, A. Unnervik, M. Nieto, O. Otaegui, and L. Salgado, "DMD: A large-scale multi-modal driver monitoring dataset for attention and alertness analysis," in *Computer Vision: ECCV 2020 Workshops*, ser. Lecture Notes in Computer Science, vol. 12538. Cham: Springer, 2020, pp. 387–405, https://dmd.vicomtech.org/.

[13] B. Bakker, B. Zabłocki, A. Baker, V. Riethmeister, B. Marx, G. Iyer, A. Anund, and C. Ahlström, "A multi-stage, multi-feature machine learning approach to detect driver sleepiness in naturalistic road driving conditions," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 5, pp. 4791–4800, 2022.

[14] Q. Massoz, J. G. Verly, and M. Van Droogenbroeck, "Multi-timescale drowsiness characterization based on a video of a driver's face," *Sensors*, vol. 18, no. 9, 2018, art. no. 2801.

[15] J. S. Wijnands, J. Thompson, K. A. Nice, G. D. P. A. Aschwanden, and M. Stevenson, "Real-time monitoring of driver drowsiness on mobile platforms using 3D neural networks," *Neural Computing and Applications*, vol. 32, no. 13, pp. 9731–9743, 2020, arXiv:1910.06540.

[16] W. Xie and P. Xiao, "Confidence-driven adaptive time window for real-time driver fatigue detection in Level 2-3 autonomous vehicles: a multi-dataset validation study," *Frontiers in Neurorobotics*, vol. 20, 2026, art. no. 1857548.

[17] A. Pradeep and W. AlSaafin, "Baseline vs exploratory deep learning video models for driver drowsiness detection: A multi-dataset evaluation," in *Proc. 6th Int. Conf. on Electrical, Computer and Energy Technologies (ICECET)*. IEEE, 2026, pp. 1–5.

[18] M. M. Rahman, M. S. Islam, M. K. A. Jannat, M. H. Rahman, M. Arifuzzaman, R. Sassi, and M. Aktaruzzaman, "EyeNet: An improved eye states classification system using convolutional neural network," in *Proc. 22nd Int. Conf. on Advanced Communication Technology (ICACT)*, 2020, pp. 84–90.

[19] R. D. Florez-Zela, "Beyond aggregate scores: Deployment-aware and non-compensatory benchmarking of vision-based eye-state recognition models for driver monitoring," Preprint, arXiv:2606.08123v2, 2026.

[20] R. Jabbar, K. Al-Khalifa, M. Kharbeche, W. Alhajyaseen, M. Jafari, and S. Jiang, "Real-time driver drowsiness detection for Android application using deep neural networks techniques," *Procedia Computer Science*, vol. 130, pp. 400–407, 2018, ANT 2018. arXiv:1811.01627.

[21] A. Dasgupta, D. Rahman, and A. Routray, "A smartphone-based drowsiness detection and warning system for automotive drivers," *IEEE Transactions on Intelligent Transportation Systems*, vol. 20, no. 11, pp. 4045–4054, 2019.

[22] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, W.-T. Chang, W. Hua, M. Georg, and M. Grundmann, "MediaPipe: A framework for building perception pipelines," arXiv:1906.08172, 2019.

[23] Y. Kartynnik, A. Ablavatski, I. Grishchenko, and M. Grundmann, "Real-time facial surface geometry from monocular video on mobile GPUs," arXiv:1907.06724, 2019, CVPR Workshop on Computer Vision for Augmented and Virtual Reality.

[24] R. Krishnamoorthi, "Quantizing deep convolutional networks for efficient inference: A whitepaper," arXiv:1806.08342, 2018.

[25] N. Petrellis, N. Voros, C. Antonopoulos, G. Keramidas, P. Christakos, and P. Mousouliotis, "NITYMED: Night time yawning-microsleep-eyeblink-driver distraction dataset," IEEE DataPort, doi:10.21227/85xe-3f88, 2022.

[26] N. Petrellis, N. Voros, C. Antonopoulos, G. Keramidas, P. Christakos, and P. Mousouliotis, "NITYMED," Kaggle (dataset), https://www.kaggle.com/datasets/nikospetrellis/nitymed, 2022, versão 1, 09/07/2022, licença CC BY-ND 4.0.

[27] N. Petrellis, S. Zogas, P. Christakos, G. Keramidas, P. Mousouliotis, N. Voros, and C. Antonopoulos, "High speed implementation of the deformable shape tracking face alignment algorithm," in *Proc. 24th Euromicro Conf. on Digital System Design (DSD)*. Palermo, Italy: IEEE, set. 2021, pp. 174–177.

[28] R. Fusek, "Pupil localization using geodesic distance," in *Advances in Visual Computing: 13th Int. Symp. on Visual Computing (ISVC 2018)*, ser. Lecture Notes in Computer Science, vol. 11241. Cham: Springer, 2018, pp. 433–444, artigo de referência do MRL Eye Dataset (http://mrl.cs.vsb.cz/eyedataset).

[29] F. Song, X. Tan, X. Liu, and S. Chen, "Eyes closeness detection from still images with multi-scale histograms of principal oriented gradients," *Pattern Recognition*, vol. 47, no. 9, pp. 2825–2838, 2014, artigo de referência do dataset Closed Eyes In The Wild (CEW).

[30] T. Åkerstedt and M. Gillberg, "Subjective and objective sleepiness in the active individual," *International Journal of Neuroscience*, vol. 52, no. 1-2, pp. 29–37, 1990, Karolinska Sleepiness Scale (KSS).

[31] J. Skorucak, A. Hertig-Godeschalk, P. Achermann, J. Mathis, and D. R. Schreier, "Automatically detected microsleep episodes in the fitness-to-drive assessment," *Frontiers in Neuroscience*, vol. 14, 2020, art. no. 8.