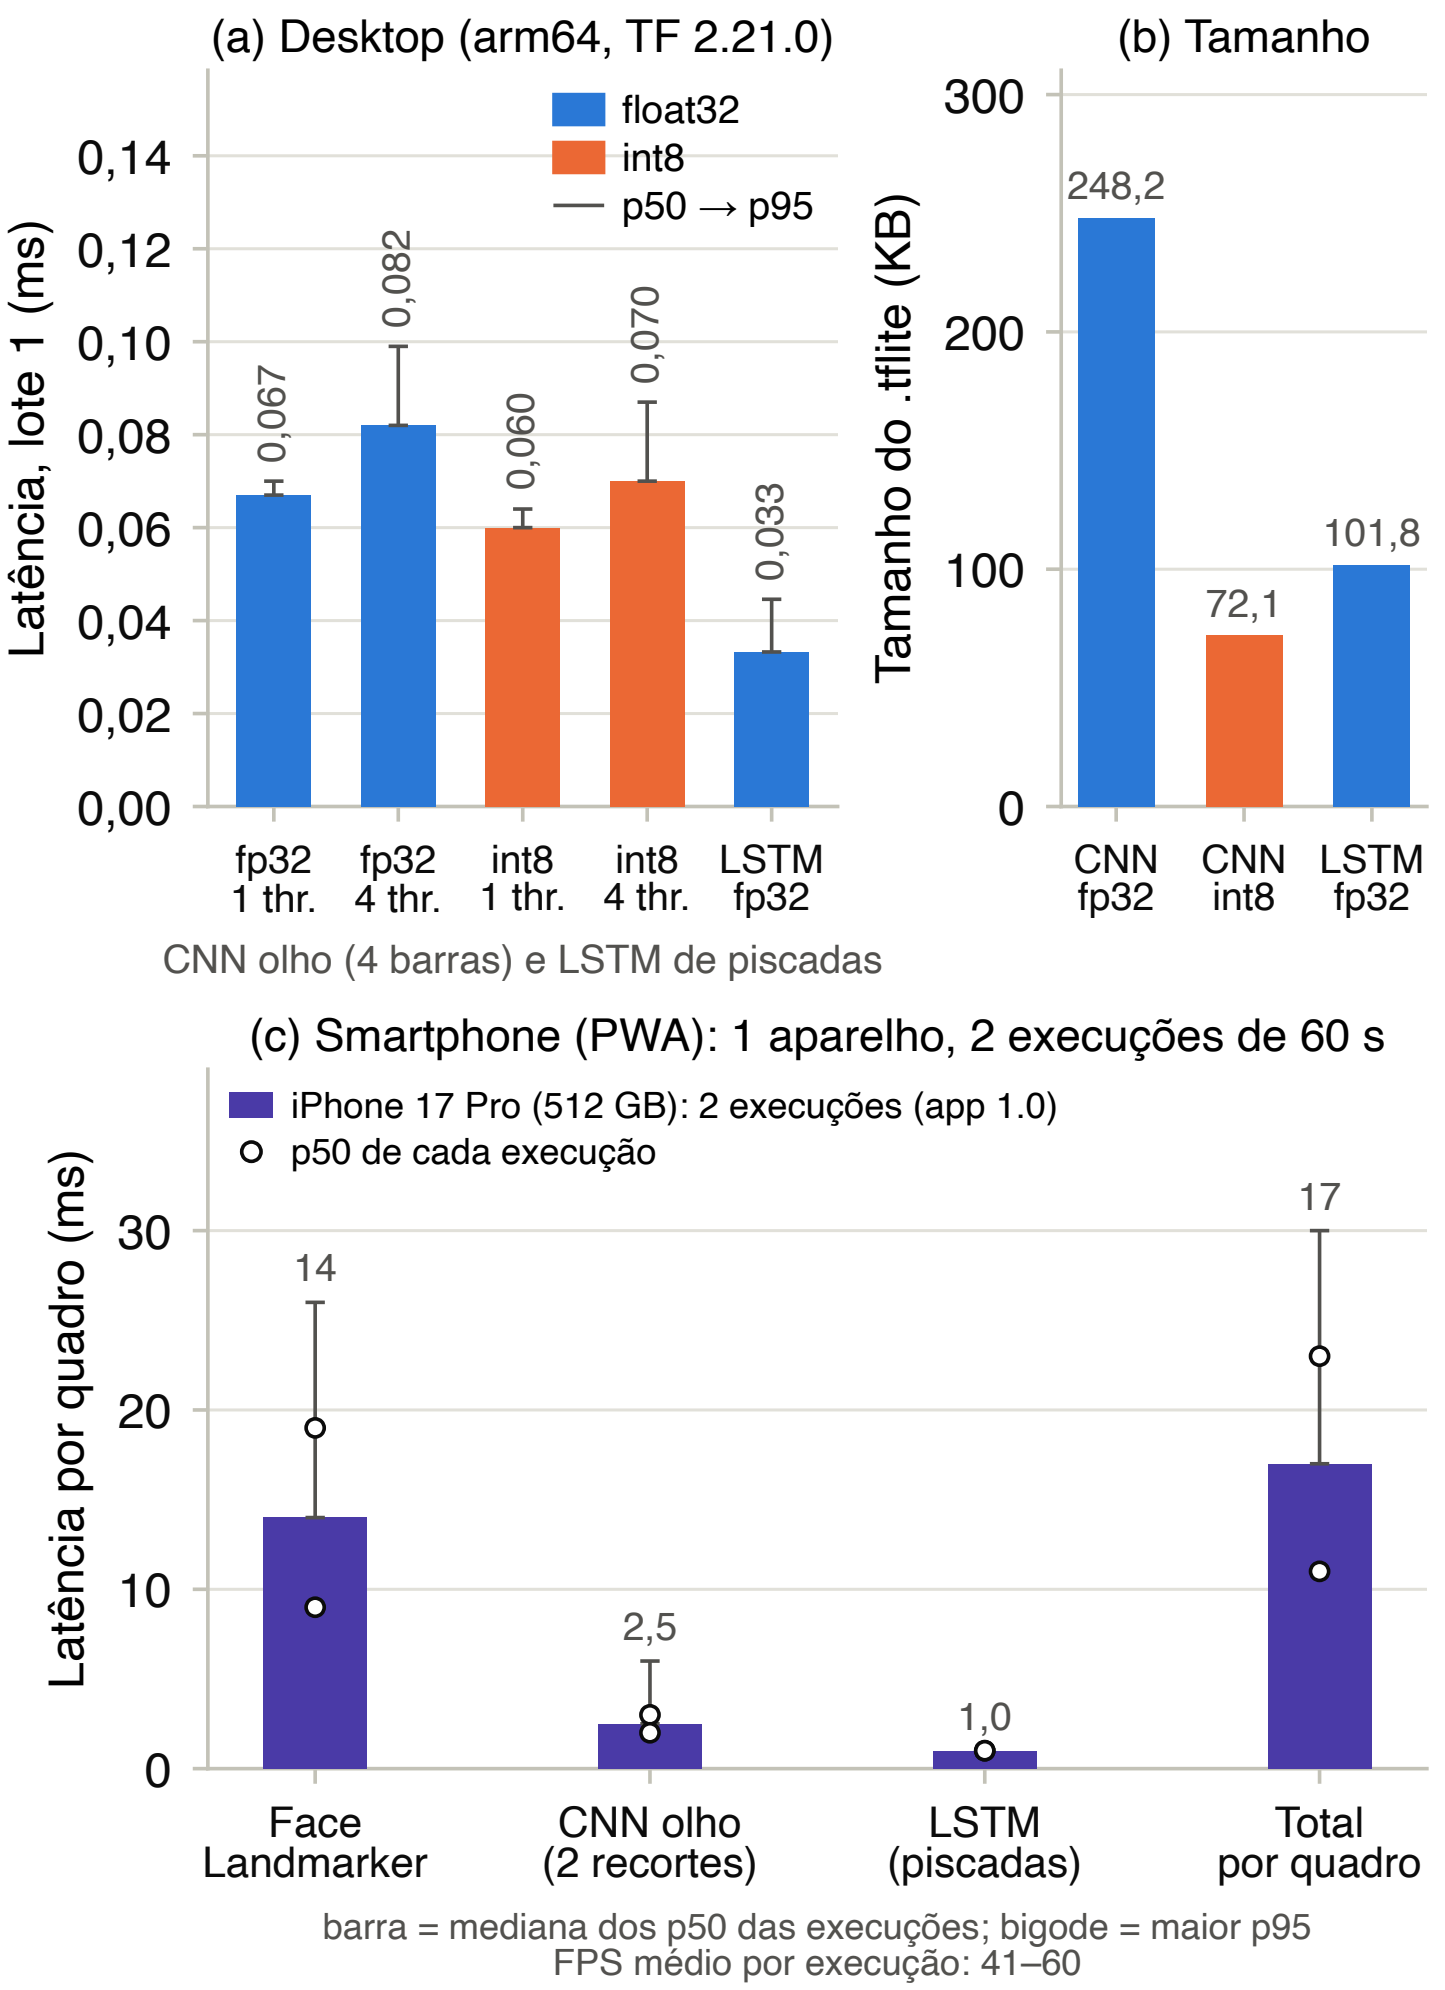
(a) Desktop (arm64, TF 2.21.0)
float32
int8
p50 → p95
Latência, lote 1 (ms)
0,14
0,12
0,10
0,08
0,06
0,04
0,02
0,00
0,067
0,082
0,060
0,070
0,033
fp32 1 thr.
fp32 4 thr.
int8 1 thr.
int8 4 thr.
LSTM fp32
(b) Tamanho
Tamanho do .tflite (KB)
300
200
100
0
248,2
72,1
101,8
CNN fp32
CNN int8
LSTM fp32
CNN olho (4 barras) e LSTM de piscadas
(c) Smartphone (PWA): 1 aparelho, 2 execuções de 60 s
iPhone 17 Pro (512 GB): 2 execuções (app 1.0)
p50 de cada execução
Latência por quadro (ms)
30
20
10
0
14
2,5
1,0
17
Face Landmarker
CNN olho (2 recortes)
LSTM (piscadas)
Total por quadro
barra = mediana dos p50 das execuções; bigode = maior p95
FPS médio por execução: 41–60